

中文图书分类号: TP311

UDC: 004

学 校 代 码: 10005



硕 士 专 业 学 位 论 文

PROFESSIONAL MASTER DISSERTATION

论 文 题 目: 心率变异性特征提取分析技术研究与应用

论 文 作 者: 赵勇

专业类别/领 域: 软件工程

指 导 教 师: 何坚 副教授

论文提交日期: 2024 年 5 月

UDC: 004 学校代码: 10005
中文图书分类号: TP311 学 号: S202175073

北京工业大学硕士专业学位论文

(全日制)

题 目: 心率变异性特征提取分析技术研究与应用

英文题目: Research and Application of Heart Rate Variability
Feature Extraction Analysis Techniques

论 文 作 者: 赵勇
专业类别/领域: 软件工程
研 究 方 向: 嵌入式软件与系统
申 请 学 位: 电子信息硕士专业学位
指 导 教 师: 何坚 副教授
所 在 单 位: 软件学院
答 辩 日 期: 2024 年 5 月
授 予 学 位 单 位: 北京工业大学

独创性声明

本人声明所呈交的论文是我个人在导师指导下进行的研究工作及取得的
研究成果。尽我所知，除了文中特别加以标注和致谢的地方外，论文中不包含其他
人已经发表或撰写过的研究成果，也不包含为获得北京工业大学或其它教育机构
的学位或证书而使用过的材料。与我一同工作的同志对本研究所做的任何贡献均
已在论文中作了明确的说明并表示了谢意。

签 名：赵勇

日 期：2024 年 6 月 1 日

关于论文使用授权的说明

本人完全了解北京工业大学有关保留、使用学位论文的规定，即：学校有权
保留送交论文的复印件，允许论文被查阅和借阅；学校可以公布论文的全部或部
分内容，可以采用影印、缩印或其他复制手段保存论文。

(保密的论文在解密后应遵守此规定)

签 名：赵勇

日 期：2024 年 6 月 1 日

导师签名：何坚

日 期：2024 年 6 月 1 日

摘要

现代社会，许多人长期承受着心理压力带来的负面影响，这种压力不仅会对身心健康造成影响，还可能导致抑郁症等严重问题，给人们的生活带来沉重的负担和痛苦。事实上现阶段抑郁症诊断存在一些挑战：目前主要依赖于临床医生的观察和使用量表进行评估，缺乏客观的生物标志物来辅助诊断。因此，探究抑郁状态的生理指标表现，深入研究其生理心理学机制，将这些指标融入计算机辅助诊断，以提升抑郁状态的识别效率。这项工作有助于及早发现抑郁症、制定更有效的治疗方案，从而减轻医疗系统的负担。

针对上述问题，本研究从心电信号中提取出连续的RR时间间隔序列，并对间隔序列的时域和频域等特征进行分析，引入了ResNet18、注意力机制和多层感知机建立心率变异性的特征提取模型，进而用于抑郁症的辅助诊断。论文的主要工作和成果如下：

(1) 针对原始心电数据存在噪声及干扰信号的问题，首先通过巴特沃斯高通滤波器对数据进行预处理；其次，使用自适应阈值法对心电信号的R峰进行定位来提取RR间隔序列，并运用滑动窗口对连续的RR间隔序列进行切片，在切片的基础上进行心率变异性的时频域特征分析；最后，利用快速傅里叶变换及功率谱密度估计将特征转换成可被残差网络识别的能量图片，使用残差网络对心率变异性的频域特征进行特征向量的提取及抑郁症的辅助诊断。

(2) 提出一种基于心率变异性多模态特征融合的抑郁症辅助诊断网络。该网络使用心率变异时频域特征作为网络模型的多通道输入，利用注意力机制进行时频域特征的多模态融合，使得重要的特征得到更多的关注，最后利用多层感知机获取风险预测的结果。

(3) 基于上述成果研发了一个面向抑郁症的辅助诊断系统，系统具有患者心电数据上传及保存、抑郁症的辅助诊断、诊断结果可视化、诊断结果下载并保存等功能。

最后在公开数据集SHAREE上进行实验，实验结果证明该系统的诊断准确率达到 87%，具有较高的可靠性和实时性，能够满足人们抑郁症辅助诊断的需求。

关键词：心率变异性；特征提取；多模态融合；残差网络；注意力机制

Abstract

In contemporary society, numerous individuals endure prolonged repercussions of psychological stress, which not only affect their physical and mental well-being but also potentially precipitate severe conditions such as depression, thus imposing a weighty burden of anguish upon their lives. Presently, diagnosing depression presents certain challenges: it heavily relies on clinical observation and the utilization of assessment scales, lacking objective biological markers to supplement diagnosis. Therefore, delving into the physiological indicators of depressive states, delving deeply into their psychophysiological mechanisms, and integrating these indicators into computer-assisted diagnostics can enhance the efficiency of identifying depressive states. This endeavor facilitates early detection of depression and the formulation of more efficacious therapeutic regimens, thus alleviating the strain on the healthcare system.

In response to the above issues, this study extracts a continuous sequence of RR time intervals from electrocardiogram signals, analyzes the temporal and frequency domain characteristics of the interval sequence, and introduces ResNet18, attention mechanism, and multilayer perceptron to establish a feature extraction model for heart rate variability, which is then used for the auxiliary diagnosis of depression. The main work and achievements of the thesis are as follows:

(1) In order to address the issue of noise and interference in the original electrocardiogram data, the data is first preprocessed using a Butterworth high-pass filter; next, an adaptive thresholding method is applied to locate the R peaks in the ECG signal to extract the RR interval sequence, which is then sliced using a sliding window approach for the analysis of heart rate variability in the time-frequency domain; finally, by employing fast Fourier transform and power spectral density estimation, the features are transformed into energy images that can be recognized by residual networks, which are used to extract feature vectors of the frequency domain characteristics of heart rate variability and assist in the diagnosis of depression.

(2) Propose a depression-assisted diagnostic network based on multimodal feature fusion of heart rate variability. This network utilizes heart rate variability time-frequency domain features as multi-channel inputs for the network model, incorporates

attention mechanisms to facilitate multimodal fusion of time-frequency domain features, placing emphasis on key features, and finally employs a multi-layer perceptron to obtain the outcome of risk prediction.

(3) Based on the aforementioned achievements, a depression-assisting diagnostic system is developed, incorporating functions such as electrocardiographic data collection, patient data upload and storage, depression-assisting diagnosis, visualization of diagnostic results, and downloading and saving of diagnostic results.

Finally, experimental validation conducted on the public dataset SHAREE demonstrates that the diagnostic accuracy of this system reaches 87%, exhibiting high reliability and real-time capability, thus meeting the needs for assisting in depression diagnosis among individuals.

Keywords: Heart rate variability, Feature extraction, multi modal fusion, Residual network, Attention mechanism

目 录

摘 要.....	I
Abstract.....	III
目 录.....	V
第 1 章 绪论.....	1
1.1 研究背景及意义.....	1
1.2 国内外研究现状.....	2
1.2.1 基于心率变异性的医疗检测技术.....	2
1.2.2 基于生理信号的抑郁症辅助诊断.....	3
1.3 研究内容.....	4
1.4 论文结构.....	5
第 2 章 相关技术基础.....	7
2.1 心电数据处理算法.....	7
2.1.1 傅里叶变换.....	7
2.1.2 功率谱密度估计.....	8
2.2 残差网络.....	9
2.2.1 残差块.....	9
2.2.2 残差网络结构.....	10
2.3 注意力机制.....	13
2.3.1 自注意力机制.....	13
2.3.2 注意力机制的应用.....	14
2.4 多层感知机.....	14
2.5 本章小结.....	15
第 3 章 HRV特征提取与分析技术	17
3.1 HRV特征分析提取总体流程	17
3.2 心率变异性数据预处理技术.....	19
3.3 HRV特征分析技术	20
3.3.1 心跳间隔检测与提取技术.....	20
3.3.2 时域特征分析技术.....	21
3.3.3 频域特征分析技术.....	23
3.3.4 滑动窗口分析技术.....	25
3.4 基于HRV和残差网络的抑郁症辅助诊断技术	26

3.4.1 基于残差网络的HRV频域特征提取	26
3.4.2 HRV频域特征分类	29
3.5 实验与分析.....	30
3.5.1 数据集.....	30
3.5.2 实验设置与评价指标.....	31
3.5.3 实验与分析.....	31
3.6 本章小结.....	32
第4章 HRV多模态特征融合技术研究	33
4.1 HRV时频域多模态特征融合概述	33
4.2 HRV时频域特征融合	34
4.2.1 HRV时域特征提取	34
4.2.2 基于注意力机制的HRV时频域特征融合	35
4.3 基于HRV多模态特征融合的抑郁症辅助诊断技术	37
4.3.1 多模态特征融合网络架构.....	37
4.3.2 基于多层感知机的辅助诊断层.....	39
4.4 实验与分析.....	41
4.5 本章小结.....	43
第5章 面向抑郁症辅助诊断系统的分析与设计.....	45
5.1 需求分析.....	45
5.1.1 功能性分析.....	45
5.1.2 非功能性分析.....	47
5.2 系统设计.....	48
5.2.1 系统架构设计.....	49
5.2.2 系统详细设计.....	51
5.2.3 数据库表设计.....	52
5.3 本章小结.....	55
第6章 面向抑郁症辅助诊断系统的实现与测试.....	57
6.1 系统实现.....	57
6.1.1 系统开发环境.....	57
6.1.2 关键算法实现及核心流程.....	58
6.1.3 系统主要模块实现.....	59
6.2 系统测试.....	64
6.2.1 系统测试环境.....	64
6.2.2 系统功能测试.....	64

6.2.3 系统性能测试.....	65
6.3 本章小结.....	67
总结与展望.....	69
参考文献.....	71
攻读硕士学位期间取得的研究成果.....	77
致谢.....	79

第1章 绪论

本章首先介绍了基于心率变异性进行抑郁症辅助诊断的研究背景及意义；其次，对国内外主流的基于心率变异性的医疗预测和抑郁症辅助诊断方法进行阐述，并分析不同方法的优缺点；最后概括介绍本文的研究内容及论文组织结构。

1.1 研究背景及意义

研究表明心理压力可分为适度 and 过度两种，适度的心理压力有助于激发个体的行动力，使人更有效地解决问题，提高工作效率；但是过度的心理压力会导致消极情绪，长时间处于这种状态会阻碍个体的反应能力，削弱个体免疫能力、增加患病风险甚至危及生命。此外，长期的心理压力还可能引发抑郁，给个体带来巨大的身心痛苦。在一些高校的心理问卷中，由于精神压力过大从而导致身患抑郁症的学生比例已经达到了 80%^[1]。根据世界卫生组织 2017 年的数据，全球的抑郁症患者数量已达到 3.5 亿，抑郁症逐渐成为人类的第二大疾病^[2]，而且发病率呈上升趋势。抑郁症不仅会引起心情低落，严重者甚至可能产生自残和自尽的念头。此外，抑郁症与心血管疾病的发病率和死亡率密切相关^[3,4]，导致个体和社会医疗费用和经济负担的加重^[5-7]。

当前，在国内抑郁症的诊断主要是依据《中国精神疾病分类方案和诊断标准（CCMD-3）》进行的，通常是要求患者填写 PHQ-9 量表^[8]来评估抑郁的程度，然后由精神科医生根据交流和观察判断患者的抑郁状态并给予评分。然而，在实际诊断过程中，一些患者处于隐私等因素可能会故意隐藏情况或不愿意积极配合；而另一些文化水平较低或老年患者可能难以准确自我评估，这些情况都会导致量表结果存在不同程度的不准确。因此，利用人体的生理指标体现出的不同特征来进行抑郁症的分类研究具有极其重要的现实意义。

由于心理压力与人体的神经系统之间有着联系，人体在心脏跳动过程中会产生一系列的电生理变化，这些电生理变化会传导到体表，通过电极可以拾取这些电信号，这些在时间轴上连续呈现的信号构成了心电图(electrocardiogram, ECG)。人体心脏跳动是有节律的，并会随时间出现微小的变动，即心率变异性(HeartRateVariability, HRV)。HRV通过个体心脏跳动有节律的微小变化反映自主神经系统（包括交感神经和副交感神经系统）对个体生理和心理的调节，具体表现为个体应激状态和平衡状态^[9]的变化。由于心率变异性与自主神经系统的活动有密切联系，因此通过对个体心率变异性的检测分析，研究其与个体情绪状

态变化的关联关系,进而评估个体精神健康状态,研发相关精神疾病的诊断预防技术和产品具有重要的研究意义。

1.2 国内外研究现状

本节将分别介绍基于心率变异性进行医疗检测技术和抑郁症辅助诊断技术的国内外研究现状。

1.2.1 基于心率变异性的医疗检测技术

人体在心脏跳动过程中会产生一系列的电生理变化,这些电生理变化会传导到体表,通过电极可以拾取这些电信号,这些信号在时间轴上连续呈现构成了心电图。研究人员发现人体自主神经系统(Autonomic Nervous System, ANS)中的交感神经和副交感神经相互作用影响,导致心脏跳动呈现出节律性并随时间发生微小变化形成HRV。HRV是近年来备受关注的项无创性心电监测指标,为了更深入地了解心脏跳动状态变化以及与自主神经系统的关联,研究人员还探讨了交感神经和副交感神经之间的交互作用。其中,ARORA等^[10]发现,舒张性心衰和收缩性心衰患者心率变异性的时频域指标都降低,但收缩性心衰患者降低程度较大,提示在舒张性心衰患者中交感-副交感神经失衡,可能是该患者群体预后较差的原因。KSELA等^[11]研究指出,射血分数保留型心衰(heart failure with preserved ejection fraction, HFPEF)患者中幸存者的SDNN相对较高。SHANKS等^[12]提出,在起搏器编程中恢复呼吸运动所引起的心率变异,即呼吸性窦性心律失常,可降低心衰患者 20%的心输出量。YUE等^[13]研究发现,隐匿性高血压患者与原发性高血压患者HRV参数都显著低于正常人群,但两者间差异无统计学意义。VIRTANEN等^[14]研究表明,高血压患者HRV的所有绝对测量值均低于正常人群。KANG等^[15]通过 10s心电图记录获得的超短期HRV测量值同样支持这个结论,并且发现HRV的增加与高血压事件呈正相关,不能在预测年轻人高血压方面发挥作用。SHARMA等^[16]从 250 篇文章中筛选出 23 篇进行进一步研究,发现基于HRV信号的机器学习和深度学习方法性能较差,不适用于辅助诊断动脉高血压。UDAWAT等^[17]提出基于机器学习方法并利用HRV对房颤进行筛查,准确率较低,可达到 75%的敏感性、65%的特异性和 70%的准确率。BUS等^[18]优化机器学习算法,使用更多的HRV参数实现对房颤的检测,在 60s心电图能够较不准确地区分房颤和窦性心律。猝死(Sudden Cardiac Death, SCD)是急性症状发生后 1h内或正常生活状态下 24h内突发的出于心脏原因的自然死亡。HEBRAHIMZADEH

等^[19]采用机器学习方法发现组合HRV信号(线性和非线性参数)在SCD发生前较长时间没有特殊特征, 其对SCD发生前 3min的预测准确率都不到 50%。MARTINEZ-ALANIS等^[20]利用支持向量机算法并基于短期记录(1000 次心搏)获得的HRV指标能作为SCD的预测因子。PARSI等和SHIRAKAWA等^[21]研究都发现, HRV新特征对室性心律失常事件预测有明显帮助, 利于及时阻止SCD事件的发生。

总的来说, 心率变异性作为一种重要的生理指标, 在健康评估、疾病预测和深度学习应用等方面具有重要的意义, 为未来的健康管理和临床诊断提供了新的思路和方法。

1.2.2 基于生理信号的抑郁症辅助诊断

抑郁症对身心健康的严重影响已经得到广泛认可, 而针对抑郁症患者的生理变化的深入研究也正在进行之中。研究发现, 抑郁症患者的生理变化主要表现为自主神经系统活动的失调, 而这种失调往往与抑郁症的程度密切相关。心率变异性作为一种测量自主神经系统活动的指标, 在研究抑郁状态方面被证实是一种可行的方法。心率变异性作为研究抑郁状态的一种方法, 能够帮助揭示抑郁症患者自主神经系统活动的失调特征, 为抑郁症的诊断、治疗和研究提供重要的生理学指标和参考。

通常使用HRV的时域、频域等指标分析探讨心率变异性与抑郁症之间的相关性。例如: 王莹^[22]等人研究发现焦虑症患者HRV的时域和频域特征值普遍低于正常人。覃晓波^[23]等人分析了广泛性焦虑症患者的长期HRV, 并揭示了焦虑症与心率变异性之间存在相关性。Kemp^[24]等人总结多项研究成果指出抑郁症患者的HRV时域特征和频域特征普遍低于健康对照组^[25]。同时患有抑郁症和焦虑症的患者特征表现得更为明显。此外, 抑郁症患者的时域指标中大于 50ms的RR间隔占比也明显低于正常人, 而频域指标中的低频成分则高于健康人^[26-28]。研究发现重度抑郁症患者的高频功率比健康人略有增加^[29,30], 而低高频比值则下降^[31]。另外, 心血管疾病也会影响HRV^[32], 这进一步增加了抑郁症检测诊断的难度。Agelink^[33]等对健康对照组、中度抑郁症患者和重度抑郁症患者的HRV开展分析研究, 结果显示在不使用抗抑郁药物的情况下, 抑郁程度越重心率变异性的时域指标RMSSD和频域指标HF值会越低。

尽管当前基于ECG信号的心率变异性特征分析提取技术在抑郁症识别领域已经取得了一些研究成果, 但大部分研究集中在比较抑郁状态患者与健康对照组的时频域数值差异, 较少关注患者能量谱方面的差异。此外, 由于数据获取难度

较大及数据处理面临的隐私和安全性等问题,尚缺少多模态特征融合的抑郁症辅助诊断技术研究。对此,本文通过抑郁症患者在静息状态下的心电数据获得HRV时频域特征,分析探讨抑郁症患者与健康对照组之间HRV时频域方面差异,并将HRV时频域特征与能量谱特征融合,探索用HRV多模态特征融合的的抑郁症辅助诊断技术,为基于HRV的抑郁症辅助诊断技术研发提供理论依据和技术支持。

1.3 研究内容

本文在研究HRV特征的特征分析提取技术基础上,探索研究基于HRV多模态特征融合的抑郁症辅助诊断技术。其中,研究原始ECG数据的预处理技术,包括确保数据准确性的原始ECG清洗去噪技术;引入滑动窗口技术,探索HRV时频域特征、功率谱特征分析技术,并结合残差网络进行HRV特征提取;最有,引入注意力机制研究HRV时频域特征融合技术,并应用上述成果将研发基于HRV多模态特征融合的抑郁症辅助诊断系统,并进行系统测试。本文研究内容的层次关系如图 1-1 所示。

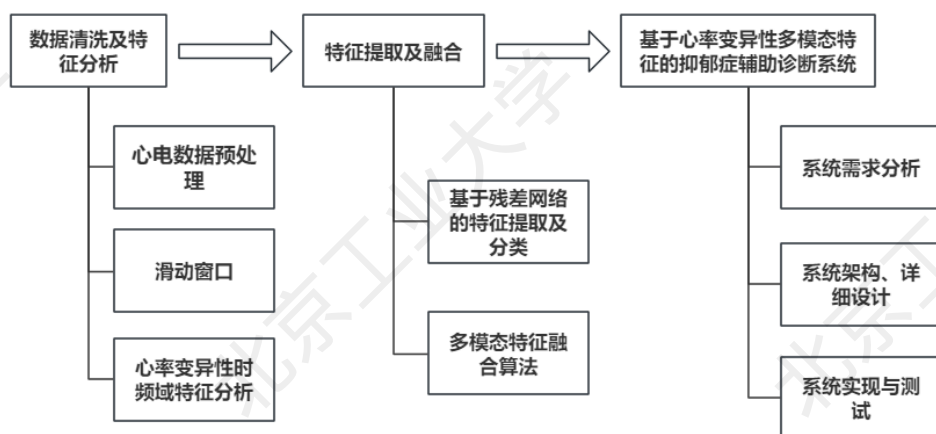


图 1-1 研究内容层次图

Fig. 1-1 Hierarchy Diagram of The Study Content

论文的具体工作如下:

(1) HRV数据清洗及特征分析技术: 原始仪器设备采集到的ECG数据易受到呼吸、运动等影响,从而造成数据缺失或产生噪声数据,进而影响后续HRV特征分析。对此,论文首先通过巴特沃斯高通滤波器对数据进行预处理;其次,使用自适应阈值法对电信号的R峰进行定位来提取RR间隔序列,并运用滑动窗口对连续的RR间隔序列进行切片,在切片的基础上进行心率变异性的时频域特征分析。

(2) 基于HRV的抑郁症辅助诊断技术: 首先,利用快速傅里叶变换及功率

谱密度估计将HRV频域特征转换成可被残差网络识别的能量图片,进而使用残差网络对心率变异性进行特征提取;其次,引入注意力机制设计了一种时频域多模态特征融合的抑郁症辅助诊断网络。其中,HRV时域数值特征与频域图像特征同时作为神经网络模型的多通道输入,并通过注意力机制进行时域特征与频域特征的融合,最后通过多层感知机对融合后的特征向量进行分类,进而提高抑郁症辅助诊断的准确率。

(3) 研发基于HRV多模态特征融合的抑郁症辅助诊断系统。其中,采用面向对象技术对抑郁症辅助诊断系统进行系统分析设计,并结合Web和数据库技术开发了具有患者心电数据上传及保存、抑郁症的辅助诊断、诊断结果可视化、诊断结果下载并保存等功能的抑郁症辅助诊断系统。

1.4 论文结构

本文每个章节安排如下:

第一章,绪论。阐述了本文的研究背景和意义,重点介绍了国内外有关心率变异性健康检测和基于生理信号进行抑郁症辅助诊断技术研究现状与趋势,并该要介绍本文的工作内容以及论文结构。

第二章,介绍本研究所涉及的相关技术基础。其中,介绍了心电数据处理过程涉及到的时频域变换算法,以及残差网络、注意力机制和多层感知机的基本结构及相关原理。

第三章,本章研究ECG数据预处理及HRV特征分析提取技术。首先,介绍了原始ECG数据预处理技术;其次,使用自适应阈值法对心电信号的R峰进行定位来提取RR间隔序列,并运用滑动窗口对连续的RR间隔序列进行切片,在切片的基础上进行心率变异性的时频域特征分析;最后,使用残差网络进行HRV特征的提取与抑郁症的辅助诊断,并在公开数据集上进行实验和结果分析。

第四章,研究基于HRV多模态特征融合抑郁症辅助诊断技术。其中,引入注意力机制进行时域特征与频域特征的融合,并结合多层感知机对融合后的特征向量进行分类,进而实现抑郁症辅助诊断。

第五章,研究设计基于HRV多模态特征融合的抑郁症辅助诊断系统。其中,采用面向对象技术对抑郁症辅助诊断系统进行系统分析,建立系统的用例模型;此外,进行了系统的构架设计、详细设计和数据库设计。

第六章，实现了系统原型，并在公开数据集SHAREE上进行实验，实验结果证明该系统的诊断准确率达到 87%，具有较高的可靠性和实时性，能够满足人们抑郁症辅助诊断的需求。

第2章 相关技术基础

本章对HRV特征提取、分析及特征融合算法相关的基础技术进行介绍，首先介绍心电数据的处理算法；其次，介绍了残差网络的核心结构和相关原理；最后，探讨了注意力机制和多层感知机的架构及原理。

2.1 心电数据处理算法

本节首先介绍心电数据处理过程中涉及到的傅立叶变换算法，用于将一个函数（或信号）在时间域中的描述转换为其在频率域中的描述。之后介绍获取心电数据中的能量涉及到的功率谱密度估计算法，该算法是描述信号在不同频率上能量分布的方法之一，功率谱密度估计可以通过对信号进行傅立叶变换来计算，得到频域上的能量分布情况，下面对这两种算法相关基础知识及计算原理进行详细介绍。

2.1.1 傅里叶变换

时域是一种直观的描述信号数据随时间变化关系的方式，惯性传感器在每个时间节点产生具体数值的信号，可通过时域波形图展示，如图 2-1 所示。




图 2-1 信号时域图

Fig. 2-1 Time-domain Plot of Signal

然而，有时候直接观察时域信号可能无法充分展现出信号的基本特征，因此需要将信号转换到更易于处理和理解的领域。为了有效地解决这一问题，可以将时域信号进行频域转换，这样可以更好地理解信号的频率成分和频域特性，在频域中，我们可以清晰地看到信号中各个频率的成分，包括基频和谐波等。通过分析这些成分的特点和强度，我们可以更准确地理解信号的特征，并进行相应的处理和分析。这种转换可以揭示心电信号中所包含的不同频率的成分及其强度，为分析和处理信号提供了更多的信息。

傅里叶变换^[34]可以实现从时域向频域转变的这个过程,傅里叶变换可以看作是傅里叶级数在连续情况下的推广,利用傅里叶变换,可将复杂波形分解成不同频率的正弦和余弦成分,有助于确定信号中的主要频率,进而理解信号的频率特性。在频域中,我们可以轻松地通过移除或抑制特定频率的成分来进行滤波操作,对于消除噪声、突发干扰或特定频率的干扰非常有用。其公式如式(2-1)所示。

$$f(w) = \int_{-\infty}^{+\infty} f(t)e^{-iwt} dt \quad (2-1)$$

其中, $f(w)$ 表示 $f(t)$ 信号波在 w 频率分量上的强度, i 为虚数单位。一般情况下,一个信号波的频域表示为自变量为频率的函数,函数值代表对应频率的强度。

2.1.2 功率谱密度估计

傅里叶变换处理后的图片并不携带额外的能量,它只是将图片在频域中的表示方式转换为频谱信息,包括图像的频率和相位信息,傅里叶变换有助于分析图像的频域特征,但不能直接用作模型的分类输入。功率谱密度 (Power Spectral Density, PSD)^[35,36] 是描述信号在不同频率上能量分布的一种方法,当对图像进行 PSD 处理后,可以得到图像在不同频率上的能量分布情况,通常情况下,图像的低频部分代表图像的整体结构和背景信息,而高频部分则代表图像的细节和纹理,其公式如式(2-2)所示。

$$PSD(f) = \frac{X(f)^2}{B} \quad (2-2)$$

有一个连续时间函数 $x(t)$, 其傅里叶变换为 $X(f)$, 其中, $x(t)$ 是信号在时域上的表示, $X(f)$ 是信号在频域上的表示。PSD 定义为 $X(f)$ 的模长平方除以信号的带宽 B , $X(f)^2$ 表示 $X(f)$ 的模长的平方, B 表示信号的带宽。为了将 PSD 定义应用于离散信号,可以将傅里叶变换改为离散傅里叶变换 (Discrete Fourier Transform, DFT)^[37,38], 其公式如式(2-3)所示。

$$X(k) = \sum_{n=0}^{N-1} x[n] * e^{\frac{-j*2\pi*n*k}{N}} \quad (2-3)$$

对于一个离散时间序列 $x[n]$, 其 DFT 变换为 $X(k)$, 其中 k 表示频域的索引, j 表示虚数单位, 该公式表示了信号在频域上的分解, 将信号分解成一系列的复数频率分量, k 取值范围是 0 到 $N-1$, 对应于频域中的离散频率点。概括来说, 这两个方法符合本文的数据预处理研究目标, 采用此种技术方案, 因其满足研究的主要需求。

2.2 残差网络

残差网络^[39,40] (Residual Network, ResNet) 是由微软亚洲研究院提出的一种深度神经网络结构，在多个深度学习任务中取得了巨大的成功，包括图像分类、目标检测和语义分割等领域。ResNet的核心思想是引入了残差学习，解决了深度神经网络难以训练的问题，是深度学习领域的重要突破之一。

ResNet的创新之处在于引入了残差学习，即假设每一层网络都应该学习残差函数以便更容易地拟合恒等映射。残差函数指的是网络应该学习的理想映射函数，即输入数据与期望输出之间的差异。因此，如果一个层的网络参数能够将输入数据与期望输出之间的差异学习到零，那么这个层的网络参数就是接近于恒等映射。

总的来说，ResNet通过引入残差学习的思想，成功解决了深度神经网络训练中的退化问题，成为了深度学习领域的重要里程碑之一。其简洁而有效的网络结构以及在各种任务上的优异表现，使得ResNet成为了深度学习领域的经典模型之一，被广泛应用于实际应用中。

2.2.1 残差块

残差块^[41,42]是残差网络的核心组件，其创新之处在于解决了训练极深卷积神经网络时出现的梯度消失和退化问题。残差块的设计使网络学习残差映射，而不是直接学习原始映射，从而显著改善了深度神经网络的训练效果，如图2-2所示。




图 2-2 残差块

Fig. 2-2 Residual Block

每个残差块包括两条路径，一条是经过一系列卷积层和非线性激活函数的主路径，另一条是通过跳跃连接实现的捷径（shortcut）。捷径直接将输入数据与主路径的输出相加，这样就生成了残差块的输出。以下是残差块的具体介绍：

（1）基本结构

残差块由两条路径组成，即主路径和捷径（shortcut）。主路径包括一系列的卷积层和激活函数，用于学习输入数据的非线性映射，而捷径则直接将输入数据传递到残差块的最后一层。在主路径的最后，主要为了与捷径的维度相匹配，可能存在一个卷积层用于调整维度。

（2）公式表示

假设输入 x ，主路径的输出为 $H(x)$ ，捷径的输出为 $F(x)$ （即输入 x 经过一些操作后得到的值），那么残差块的输出可以表示为： $H(x) + F(x)$ 。残差块的目标是学习一个残差映射 $F(x)$ ，以使网络更容易拟合恒等映射。

（3）恒等映射

在实际训练中，希望主路径学习到的映射 $H(x)$ 能够逼近于恒等映射，即 $H(x) + F(x) \approx x$ 。这样，如果网络学习到了一个恒等映射，那么残差映射 $F(x)$ 就趋近于零，此时残差块就退化成了没有主路径的简单传播。如果残差映射 $F(x)$ 较小，表示主路径已经包含了大部分输入数据的信息，而残差块的输出与输入之间的差异很小。

（4）恒等映射与跳跃连接

为了实现恒等映射的学习，残差块采用了跳跃连接的机制，将输入数据直接传递到残差块的输出最终与主路径的输出相加。这种跳跃连接确保了梯度可以直接回传到更浅的层，有助于解决梯度消失问题。

（5）特征维度变换

为了确保主路径和捷径的维度匹配，有时需要在残差块中使用额外的卷积层来对输入进行维度调整，以便使得 $H(x)$ 和 $F(x)$ 的维度一致。

总的来说，残差块通过引入了残差的概念和跳跃连接的方式，有效地解决了深度神经网络训练中的梯度消失和退化问题，为设计和训练深层神经网络提供了非常有效的思路。这种结构的巧妙设计使得网络更易于训练，有助于构建更深层的神经网络模型，并在计算机视觉等领域取得了显著的性能提升。

2.2.2 残差网络结构

（1）输入层

接受输入数据的层，可以是图像、文本或其他形式的数据。

(2) 卷积层

卷积层通过卷积操作对输入数据进行特征提取。卷积操作是一种有效地从输入数据中提取局部特征的方法，它通过滑动一个称为卷积核（或过滤器）的小窗口在输入数据上进行扫描，并计算每个位置的加权和。这个过程可以捕获到输入数据的空间信息，例如边缘、纹理等。卷积层中的卷积核是由一组可学习的参数组成的小矩阵，它决定了卷积操作中的权重。通过反向传播算法，网络可以自动学习到合适的卷积核参数，从而使网络能够有效地提取输入数据中的特征。

在进行卷积操作时，可以通过调整步幅（stride）和填充（padding）参数来控制输出特征图的大小。步幅决定了卷积核在输入数据上滑动的步长，而填充则可以在输入数据的周围添加额外的值，以控制输出特征图的大小和形状。在卷积操作之后，会应用一个激活函数来引入非线性。常用的激活函数包括ReLU（Rectified Linear Unit）、sigmoid和tanh等，它们能够增强网络的表达能力，并帮助网络学习复杂的非线性关系。

在残差网络中，卷积层^[43]通常是由多个堆叠在一起的卷积层组成，通过这种堆叠的方式，网络可以逐渐提取输入数据的更高级别的抽象特征，从而实现更加深层次的特征学习和表示

(3) 残差块

每个残差块包括两个关键部分：标准路径和跳跃连接。标准的路径包括一系列的卷积层、批量归一化（Batch Normalization）以及非线性激活函数（如ReLU）。这些层堆叠在一起，通过卷积和激活函数对输入数据进行特征提取和变换以达到学习的目的。

跳跃连接是残差块的关键所在。它将输入数据直接传递到残差块的输出，并与标准路径的输出相加，这使得残差网络能够学习残差映射，也就是输入与预期输出之间的差异。通过这一机制，网络可以更容易地适应恒等映射，避免了梯度消失问题，使得网络更容易进行优化。跳跃连接还允许梯度直接回传到更浅的层，增强了信息流动，有助于优化网络的训练。

残差块的设计可以有不同的变体，例如，基于瓶颈结构的残差块提供了更高效的计算和额外的表达能力。瓶颈结构由一个 1×1 卷积层、一个 3×3 卷积层和一个 1×1 卷积层组成，分别用于减少和还原特征的维度。

(4) 池化层

池化层^[44-46]通过对输入的特征图进行降采样操作，减小特征图的尺寸，池化操作通常使用固定大小的池化核，在输入特征图上滑动以执行采样。池化核的

大小决定了每个池化区域的空间范围，而步幅则决定了池化操作的滑动步长。通过调整这两个参数，可以控制输出特征图的大小和维度，通过将每个池化区域的特征进行聚合，实现了对输入特征的降维和不变性。这意味着即使输入特征发生轻微的平移或变形，池化层仍能够提取出相似的特征表示，从而增强了网络对输入数据的鲁棒性，池化层的降采样效果可以减少特征图的尺寸，从而降低了网络的参数数量和计算复杂度，有助于防止模型过拟合训练数据。

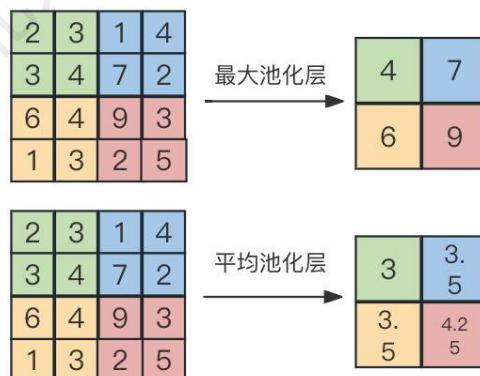


图 2-3 最大值池化与平均值池化

Fig. 2-3 Max Pooling and Mean Pooling

最常见的池化操作是最大池化 (Max Pooling) 和平均池化 (Average Pooling)。最大池化将输入特征图划分为不重叠的区域，并在每个区域中选择最大值作为输出，而平均池化则选择每个区域的平均值作为输出，如图 2-3 所示，它们适用于不同的场景。

在残差网络中，池化层通常被用于在卷积层之间进一步降低特征图的尺寸，并逐渐减少特征图的空间维度。这有助于提取出更加抽象和高级别的特征表示，从而实现更深层次的特征学习和模型训练

(5) 全连接层和分类器

最后可以添加一个或多个全连接层^[48,49]，将特征向量映射到预定义类别或目标空间。如果是图像分类任务，通常的做法是通过全连接层连接一个 Softmax 分类器，最终输出每个类别的概率分布。

通过残差学习，梯度可以直接回传到更浅的层从而减轻了梯度消失问题。此外，残差网络的设计使得在增加网络深度时，模型的性能不会下降反而可能会提高。这种创新性的设计极大地推动了深度学习领域的发展并在实践中取得了巨大成功。

总的来说, ResNet引入了残差学习的思想, 通过设计残差块解决了深度网络训练难题进而构建了更深层次的神经网络模型, 在图像识别等领域取得了显著效果, 这一创新对深度学习理论和实践都带来了重大影响。

最后, 残差网络的基本结构是通过堆叠残差块来构建深层神经网络。每个残差块包含标准路径和跳跃连接, 利用残差学习的思想来学习输入数据的残差映射。这种结构成功解决了深度网络训练困难的问题并在图像分类、目标检测等任务中取得了重要的突破和应用。

2.3 注意力机制

注意力机制^[50-52]是一项重要机制, 允许深度学习模型在处理输入数据时, 将关注点置于相关的部分或特征上。通过该机制, 模型能够自动选择性地关注输入中的重要信息, 而忽略掉不相关或噪声部分。在注意力机制中, 赋予重要信息更高的权重, 而对于不重要的信息则给予较低的权重, 通过这种机制, 模型可以更加精确地处理数据, 提取关键特征, 并在各种任务中获得更好的性能。注意力机制基本结构包括自注意力机制和注意力机制的应用两个方面, 下文将对这两个方面进行详细介绍。

2.3.1 自注意力机制

自注意力机制^[53]用于处理序列数据, 例如文本或时间序列。它能够在输入序列的不同位置上分配不同的重要性权重, 从而实现对序列中不同元素的关注。自注意力机制的基本结构如下:

(1) 输入序列: 假设输入序列包含 N 个元素, 可表示为 $X = \{x_1 x_2 \dots x_n\}$, 其中每个元素 x_i 是输入序列的一个位置。

(2) 在自注意力机制中, 查询(Query)、键(Key)和值(Value)三个线性变换矩阵被用来计算注意力权重。每个输入序列中的元素 x_i 都会对应生成查询向量 q_i 、键向量 k_i 和值向量 v_i 。这个过程能够帮助模型更好地理解输入序列的关系和重要性, 进而更精确地处理数据从中提取关键特征。

(3) 注意力权重: 通过计算查询向量和键向量之间的相似度(通常使用点积或者加性注意力机制), 得到每个元素与其他元素的关联程度, 再通过Softmax函数将相似度转换为注意力权重, 表示每个元素对其他元素的重要性。

(4) 加权求和: 利用上一步中计算的注意力权重, 对值向量进行加权求和, 以生成最终的表征。对于第 i 个元素 x_i , 其最终表示经过注意力权重加权求和后得到的新表示为 $z_i = \sum(\text{attention_weight} * v_i)$ 。

(5) 多头注意力^[54]: 为了提高模型的表达能力, 自注意力机制通常采用多头机制, 即使用多组不同的查询、键、值矩阵进行注意力计算, 最后将每组注意力计算的结果拼接或者加权求和, 从而得到最终的表示。

2.3.2 注意力机制的应用

在深度学习模型中, 注意力机制经常被用于不同的任务和模型结构, 比如机器翻译、文本生成以及图像分类和目标检测等计算机视觉任务。在这些应用中, 注意力机制的基本结构如下:

(1) 上下文向量: 在自注意力机制中, 最终的加权求和得到的表示一般被称为上下文向量, 表示了输入序列中各个位置的权重。这个上下文向量可以用于后续任务的处理, 例如作为编码器-解码器模型中解码阶段的输入, 或作为序列分类任务的最终表示。

(2) 应用于不同领域: 在自然语言处理中, 注意力机制被广泛应用于自动语言翻译、语言建模和文本生成等任务, 通过着重关注输入序列中与当前位置相关的信息来提高模型的性能。在计算机视觉中, 注意力机制可以用于生成图像描述、图像分类和目标检测等任务, 使模型能够聚焦于图像中的关键区域或特征。

总体来说, 注意力机制的基本结构由自注意力机制和注意力机制的应用两个方面构成。自注意力机制通过计算查询、键、值和注意力权重实现对输入序列不同位置的关注, 应用于各种任务中以提升模型的性能和表征能力, 注意力机制用来提取重要特征值从而提高模型的性能和泛化能力。

2.4 多层感知机

多层感知机^[55-57] (Multilayer Perceptron, MLP) 是神经网络模型的基本组成部分, 包括一个或多个隐藏层和一个输出层, 形成了前馈神经网络的结构。每个隐藏层和输出层都包含多个神经元, 每个神经元与前一层的所有神经元相连接。MLP 通过学习权重参数, 将输入数据映射到所期望的输出结果。在隐藏层和输出层之间通常应用非线性的激活函数, 以引入非线性变换, 增强模型的表达能力。

MLP 可用于各种机器学习任务，例如分类、回归等。下面对**MLP**的结构进行详细介绍：

(1) 输入层：输入层接收原始数据的特征向量作为输入，每个输入节点对应一个特征。输入层的节点数量由特征的维度确定。

(2) 隐藏层：隐藏层是神经网络中的一个重要组成部分，通常位于输入层和输出层之间。与输入层和输出层相比，隐藏层的作用有些隐秘，但却是神经网络实现非线性拟合和复杂模式学习的关键所在。通过引入非线性变换，扩展了神经网络的表示能力，使其能够学习和表达更加复杂的模式和关系。这种非线性变换可以是各种激活函数的作用，它们能够将输入信号映射到一个非线性的空间中，从而使得神经网络可以逼近各种复杂的函数。

(3) 输出层：输出层接收来自最后一个隐藏层的信号，并产生最终的输出。输出层的节点数量通常取决于具体的任务，如分类任务可能对应于不同的类别数量，回归任务可能对应于预测的连续值。

在多层感知机的每一层中，神经元会将前一层的输出乘以权重并相加，然后通过激活函数进行非线性处理，得到神经元的输出。常见的激活函数有sigmoid、tanh 和 ReLU。**MLP** 通过反向传播算法和梯度下降等方法来调整网络中的权重，以最小化损失函数，从而实现对输入数据的学习和预测。**MLP** 可以用于各种机器学习任务，例如图像识别、语音识别、自然语言处理等。除此之外，神经网络还可以通过不断迭代训练来提高模型的性能和泛化能力。

2.5 本章小结


本章对**HRV**特征提取、分析及特征融合过程中涉及到的主要技术进行了介绍，包括：心电数据处理算法、残差网络、注意力机制和多层感知机。在后续的内容中，我们将更加详细地讨论这些技术在各个领域的应用和具体实践。

第3章 HRV特征提取与分析技术

本章首先对原始ECG数据进行清洗、滤波等预处理，以提高ECG数据的可靠性；其次，使用自适应阈值法对心电信号的R峰进行定位来提取RR间隔序列，并运用滑动窗口对连续的RR间隔序列进行切片，在切片的基础上进行心率变异性的时频域特征分析；最后，利用快速傅里叶变换及功率谱密度估计将特征转换成可被残差网络识别的能量图片，使用残差网络对心率变异性的频域特征进行特征向量的提取及抑郁症的辅助诊断，并在公开数据集上进行实验和结果分析进行分类进而实现抑郁症的辅助预测，在公开数据集上进行实验并分析实验结果。


3.1 HRV特征分析提取总体流程

抑郁症与自主神经功能相关联，发病期间时会出现血管扩张、心跳加速等症状。因此，在ECG数据基础上提取心跳间隔序列，分析其HRV特征是进行抑郁诊断的必要步骤。图 3-1 对比了正常人与抑郁症患者的心跳间隔图像，其中横轴表示一分钟内心跳间隔序列，纵轴表示这次心跳与上一次心跳的时间差。图 3-1(a) 为健康对照组心跳间隔序列，其时间差均值为 886.12，一分钟心跳次数为 68 次；图 3-1(b) 为抑郁症患者的心跳间隔序列，其时间差均值为 793.54，一分钟心跳次数为 77 次。由此可见，抑郁症患者的时间差均值显著低于健康对照组。基于上述健康对照组与抑郁症患者在HRV上存在的区别，本文首先对HRV时频域特征进行分析，并研究相关特征提取技术。



(a) 正常人心跳间隔

(a) Normal Heartbeat Interval



(b) 抑郁症患者心跳间隔

(b) Heart Intervals in Depressed Patients

图 3-1 心跳间隔图

Fig. 3-1 Heart Rate Interval Plot

本文提出的HRV特征分析及提取整体流程框架如图 3-2 所示。主要包含：数据预处理、R峰检测、提取RR间隔、特征分析、特征提取五个方面，接下来对这五个方面进行介绍。



图 3-2 HRV特征分析及提取流程图

Fig. 3-2 HRV Feature Analysis and Extraction Flow Chart

(1) 数据预处理

通常仪器设备采集到的原始ECG数据易受到呼吸、运动等影响，从而造成数据点缺失或产生数据噪声，进而对后续分析产生影响。对此为了准确可靠提取HRV的特征值，需要对数据ECG进行降噪等预处理。

(2) 波峰检测

获取HRV特征值，以需要对连续ECG信号中的波峰进行标记。其中，波峰通常为ECG波形信号中的最大值点或局部最大值点。针对预处理后的ECG数据，对其QRS波进行波峰检测，标记出波峰（R峰），从而确定心跳周期。

(3) 提取RR间隔

针对标记了R波峰的ECG数据，按照时间序列依次计算连续RR间隔的，进行RR间隔时间序列，为后续HRV特征提取提供基础。

(4) 特征分析

由于连续RR间隔的变化能够反应自主神经对身体和心理功能的调节状态。因此可以从时域、频域、功率谱密度等方面对HRV进行特征分析。

(5) 特征提取

针对分析出的HRV时域、频域、功率谱密度等特征，所以需要设计相应特征提取算法，为后续抑郁辅助诊断提供决策支持。

3.2 心率变异性数据预处理技术

原始心电数据可能受到诸如基线漂移、肌肉运动、电极脱落等不同因素的影响，这些因素会导致数据误差或噪声，进而影响对ECG数据正确分析。数据预处理通过噪声滤波、去除基线漂移等方法可以减少噪声的影响，提高ECG数据质量及其可解释性。

滤波、降噪技术可用于原始信号的预处理，已减少或去除原始信号中的干扰成分，提高信号质量和准确性。滤波的主要目的是去除信号中的噪声或其他不需要的成分，使得信号更加干净和可靠；降噪是通过信号处理等方式减少或消除噪声信号的干扰，以提高数据的质量和可靠性。基线漂移是指传感器或监测系统输出的信号随时间发生的漂移现象，特别是在长时间监测过程中，可能导致误差逐渐积累，从而影响结果的准确性和可靠性。由于个体心率通常在 60~120Hz左右，因此本文采用巴特沃斯高通滤波器^[58]对原始ECG数据进行滤波降噪。

巴特沃斯高通滤波器(Butterworth high-pass filter)是一种常见的滤波器类型，用于在频域中强调高频分量，并抑制低频分量，其传输函数如公式(3-1)所示。

$$H(s) = \frac{G}{1 + (\frac{s}{\omega_c})^n} \quad (3-1)$$

其中， $H(s)$ 是频率域中的传输函数； s 是频域变量； G 是增益因子； ω_c 是截止频率； n 是滤波器的阶数。巴特沃斯高通滤波器的原理是通过控制传输函数的幅度响应使得低频信号的幅度下降，而高频信号的幅度保持较高，滤波器的阶数决定了滤波器的斜率，阶数越高滤波器的速度降低就越快。

基线漂移一般是由个体呼吸和器件电极变化所导致的，频率一般低于 1Hz，主要分量在 0.1Hz左右。所以在使用巴特沃斯滤波器处理过程中，将截止频率 ω_c 设置为 10hz，滤波器的阶数 n 设置为 3 阶，这样可以有效杜绝基线漂移对有效ECG信号的干扰。如图 3-3 所示，上面的为原始数据的心电图，下面则为经过数据预处理后的心电图，从图中可以看到，原始数据在没经过处理前，会有连续不间断起伏的小心电信号，波峰到波谷的距离明显比其他波峰波谷小(即伪波峰)，它是相邻点的最大值但不是超过阈值的波峰与波谷。而经过滤波后的数据，明显

过滤掉了这些伪波峰的干扰。经过预处理后的数据，可为后续ECG数据的精准特征分析提供了基础。




图 3-3 数据预处理对比图

Fig. 3-3 Data Preprocessing Comparison Diagram

3.3 HRV特征分析技术

HRV^[59,60]分析主要包括心跳的波峰检测、波峰与波峰之间时间间隔序列的获取以及波峰与波峰之间时间间隔序列的特征分析。本节首先从连续心跳的QRS波中获取R波峰，然后根据R波峰所对应的时间点来构建出相邻的RR时间间隔序列；其次，运用滑动窗口进行HRV的特征分析，包括对RR时间间隔序列的时域特征分析、频域特征分析。

3.3.1 心跳间隔检测与提取技术

HRV是指心跳间隔变化。要想获得心跳间隔变化，首先需要获取R波，找到波峰的位置；其次，在波峰对应的时间序列上，找出波峰对应的时间差。

(1) RR波峰检测

心电图是用来记录心脏电活动的一种图形记录。完整的心电图如图 3-4 所示。其中，R波峰值是心电图QRS波群中的最高峰值，通常代表心脏的心室收缩。检测R波峰值在心电图分析中非常重要，它是计算心率、分析HRV特征的基础。

基础。使用基于阈值法在QRS波中精确找到R波步骤：首先对处理好的数据进行基线的寻找，基线是心电图波形的平坦部分，根据基线的特征如平均值等可以计算出一个适当的阈值；其次，对处理好的心电数据进行扫描，将心电信号波峰的幅值和阈值进行比较，若波峰幅值超过阈值则判断为R波，根据R波的判定结果可以定位R波在心电图中的位置。

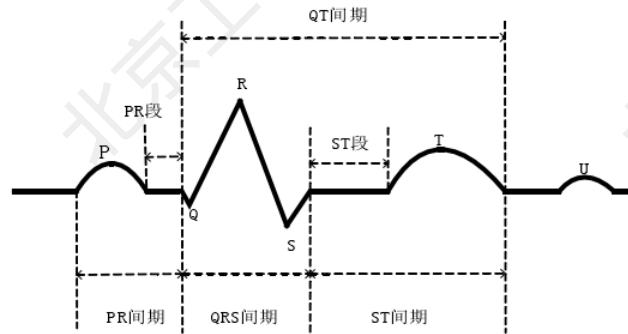


图 3-4 QRS波

Fig. 3-4 QRS Wave

(2) 心跳间隔提取

如图 3-5 所示，一旦确定了R波的位置可以根据时间序列中每个R波对应的时间节点，来计算每个相邻R波之间的时间差从而得到一系列的RR间隔^[61]，即相邻的心跳间隔时间序列。这个RR时间间隔序列包含了宝贵的心率和心律相关信息，对于后续的疾病诊断、健康研究以及生物医学工程领域的实践具有重要意义。




图 3-5 相邻R峰心跳间隔

Fig. 3-5 Adjacent Peak R Heartbeat Interval

3.3.2 时域特征分析技术

时域特征是描述心率变异性的常用统计量，用来分析和量化心率信号沿时间轴变化的特征。RR间隔的时域特征主要为统计学特征，将RR间隔提取后对RR时间间隔的变化情况进行统计学分析。本文分析的时域特征有：心跳间隔的标准差（Standard Deviation of NN intervals, SDNN），相邻RR间隔差值大于 50 毫秒的点占总体的比例（percentage of NN50, PNN50），相邻RR间隔差值的均方根

值（Root Mean Square of Successive Differences, RMSSD），其生理意义见表 3-1。其中，SDNN 反应了心率变异性的总体情况，RMSSD 反应了副交感神经活动，PNN50 反应了交感神经调控，三者值的高低可反应自主神经调节能力和更健康的的心脏状态。

表 3-1 HRV 时域特征表

Tab. 3-1 HRV Time Domain Characteristic Table

分析方法	指标	生理意义
时域分析	SDNN	反应心率变异性总体情况
	RMSSD	反应副交感神经活动
	PNN50	反应副交感神经调控

(1) RMSSD: 相邻RR间隔之差的均方根，其公式如（3-2）所示。

$$RMSSD = \sqrt{\frac{1}{N-1} \sum_{i=1}^{N-1} (RR_{i+1} - RR_i)^2} \quad (3-2)$$

(2) SDNN: 连续正常的RR间隔的标准差，其公式如（3-3）所示。

$$SDNN = \sqrt{\frac{1}{N} \sum_{i=1}^N (RR_i - \overline{RR})^2} \quad (3-3)$$

(3) PNN50: 相邻正常R-R间隔差值大于 50ms 的个数占总心跳次数的百分比，其公式如（3-4）所示。

$$pNN50 = \frac{\text{count}(|RR_{i+1} - RR_i| > 50\text{ms})}{N-1}, i = 1, 2, \dots, N-1 \quad (3-4)$$

本文随机截取一段心电数据对其作时域特征分析，如图 3-6 所示。




图 3-6 连续心跳间隔图

Fig. 3-6 Continuous Heartbeat Interval Diagram

其RMSSD值为 56.0，SDNN的值为 34.0，pNN50 的值为 22.6，这些值都在参考范围且指标值普遍偏小，反应了心率变异性的活性较低，表明了该心电数据属于抑郁症患者。

3.3.3 频域特征分析技术

频域特征是用来描述心率变异性中的频率成分特征。本文中分析的频域特征有：非常低频带（Very Low Frequency, VLF），低频带（Low Frequency, LF），高频带（High Frequency, HF），低频功率与高频功率的比值（LF/HF比率），其生理意义见表 3-2。其中，VLF反应了心率的低频振荡成分，LF反应了交感与副交感神经的双重调节，HF反应了副交感神经的调节，LF/HF反应了交感-副交感神经的均衡性。这些特性可以很好的反应出个体HRV的活性。此外，时域与频域特征融合可以更全面地了解HRV及其与心脏活动和自主神经功能间的关系。

表 3-2 HRV频域特征表

Tab. 3-2 HRV Frequency Domain Feature List

分析方法	指标	生理意义
频域分析	VLF	反应了心率的低频振荡成分
	LF	反应交感与副交感神经的双重调节
	HF	反应副交感神经调节
	LF/HF	反应交感—副交感神经的均衡性

(1) VLF: 极低频功率，其公式如 (3-5) 所示。

$$VLF = \int_{0.003}^{0.15} PSD(f)df \quad (3-5)$$

(2) LF: 低频功率，其公式如 (3-6) 所示。

$$LF = \int_{0.04}^{0.15} PSD(f)df \quad (3-6)$$

(3) HF: 高频功率，其公式如 (3-7) 所示。

$$HF = \int_{0.15}^{0.4} PSD(f)df \quad (3-7)$$

(4) LF/HF: 低频与高频的比值。

信号从时域转换成频域需要用到快速傅里叶变换（Fast Fourier Transform, FFT），其公式如 (3-8) 所示： f 是 x 的频率分量， t 表示时间，公式可以理解为时域信号 $x(t)$ 乘上一个由指定频率组成的指数项 $e^{-2\pi ift}$ ，然后在整个时间轴上进行积分，得到了频域信号，它的作用是识别出信号中的频谱分量。

$$S(f) = \int_{-\infty}^{+\infty} x(t) * e^{-2\pi ift} dt \quad (3-8)$$

具体的做法是利用快速傅里叶变换^[63]将时间序列信号分解成不同的频率成分，其公式如 (3-9) 所示。

$$h(x) = f(x)g(x) \quad (3-9)$$

其中， $f(x)$ 如式 (3-10) 所示。

$$f(x) = a_0 + a_1x + a_{n-1}x^{n-1} \quad (3-10)$$

$g(x)$ 如式(3-11)所示。

$$g(x) = b_0 + b_1x + b_{n-1}x^{n-1} \quad (3-11)$$

为求得 $h(x)$ 的系数,使用系数表示法的时间复杂度为 $O(n^2)$,而使用点值表示法的时间复杂度为 $O(n)$ 。由于多项式乘法用点值表示比用系数表示快得多,因此可以先将系数表示法转化成点值表示法相乘,再将结果的点值表示法转化为系数表示法。第一个过程叫做FFT,第二个过程叫IFFT。将 $f(x)$ 的每一项按照奇偶性分为以下两部分,如式(3-12)所示。

$$f(x) = a_0 + \dots + x * (a_1 + a_3x^2 + a_{n-1}) = A_0(x^2) + x * A_1(x^2) \quad (3-12)$$

代入 $x = w_n^k$, $k < n$, 则变为式(3-13)所示。

$$A(w_n^k) = A_0(w_n^{2k}) + w_n^k * A_1(w_n^{2k}) = A_0\left(w_n^{k+\frac{n}{2}}\right) - w_n^k * A_1\left(w_n^{k+\frac{n}{2}}\right) \quad (3-13)$$

考虑到 $A_0(x)$ 和 $A_1(x)$ 分别在 $(w_n^1, w_n^2, \dots, w_n^{n-1})$ 值表示已经求出,就可以求出 $A(x)$ 在 $(w_n^1, w_n^2, \dots, w_n^{n-1})$ 处的点值表示,这个操作叫做蝴蝶变换。

本文随机截取一段心电数据来做频域特征分析。RR间隔序列经过快速傅里叶变换之后如图3-7所示。




图 3-7 频谱图

Fig. 3-7 Spectrum Graph

横轴表示频率,纵轴表示频率分量的幅度。其中极低频值为1256.6,低频值为52.9,高频值为37.1,低频高频比为1.5,极低频值、低频值和高频值偏低,而低频高频比偏高,反应了心率变异性活性较低,由此得出该心电数据来自一名抑郁症患者。时频域指标不仅能反应心率变异性的活性,还可以反映心率变异性的节律性和整体稳定性,而且这些指标在后续的健康评估以及生理研究中具有重要的应用意义。

3.3.4 滑动窗口分析技术

对原始数据进行预处理之后,需要对处理后的数据进行时频域特征分析。由于心电数据是一个连续的动态生理信号,具有连续性和长期性等特征,而传统的针对静态数据的分析方法无法适用于此场景。对此,本文引入滑动窗口技术^[62]。由于不同的滑动窗口大小对后续的研究产生的影响不同,所以本文分别采用 10s、20s、30s的窗口大小进行实验,通过实验结果分析选择合适的窗口大小,进而保证后续HRV特征的准确提取。

本文先采用 10s的滑动窗口对处理后的数据进行统计学分析,总时长采用 300s的数据,数据取所有窗口的平均值,其值见表 3-3。

表 3-3 窗口为 10s统计学特征

Tab. 3-3 Statistical Characteristics With a Window of 10s

指标	结果	参考范围
SDNN	20.1	18.1~105.5
RMSSD	12.8	9.4~77.5
PNN50	0.5	0.2~49.8

SDNN、RMSSD、PNN50 的值明显在参考范围的下限徘徊,可能与窗口选取太小导致无法准确反应心率在较长时间尺度上的变化和调节。

其次,采用 20s的窗口进行实验,其值见表 3-4。

表 3-4 窗口为 20s统计学特征

Tab. 3-4 Statistical Characteristics With a Window of 20s

指标	结果	参考范围
SDNN	84.0	18.1~105.5
RMSSD	76.0	9.4~77.5
PNN50	45.6	0.2~49.8

SDNN、RMSSD、PNN50 的值在参考范围内且与正常数据相差不大。

最后,采用 30s的窗口进行实验,其值见表 3-5。

SDNN、RMSSD、PNN50 的值在参考范围的上限徘徊,可能与窗口选取太大导致样本数量有限从而导致统计的不稳定性。

表 3-5 窗口为 30s统计学特征

Tab. 3-5 Statistical Characteristics With a wWindow of 30s

指标	结果	参考范围
SDNN	110.4	18.1~105.5
RMSSD	92.5	9.4~77.5
PNN50	60.1	0.2~49.8

由于窗口在 20s 大小时，时域值更接近正常水平，故综合考虑心电信号长期趋势的捕捉以及样本数据量后，本文采用大小为 20s 的滑动窗口来进行 RR 时间间隔的特征分析，如图 3-8 所示。




图 3-8 滑动窗口图

Fig. 3-8 Sliding Window Diagram

ECG 数据总时长为 5 分钟，一个红色窗口为 20s 的心电数据，滑动大小为 10s。通过滑动窗口缓存心电数据，并对每一个窗口内的 ECG 数据进行波峰检测以及特征分析，设置对应的时间戳，保存其时频域特征值。随着新数据的持续涌现，滑动窗口采用先进先出原则持续更新窗口内的数据，并保存分析结果。

3.4 基于 HRV 和残差网络的抑郁症辅助诊断技术

对分析好的 RR 时间间隔特征，肉眼难以分辨其中的差别，故本文采用深度学习模型进行特征的提取以便完成二分类辅助预测任务。针对心率变异性特征的提取以及抑郁症的辅助预测任务，本文使用一种残差网络模型，即 ResNet18。该模型的创新之处在于解决了训练极深卷积神经网络时出现的梯度消失和退化问题，最后，利用残差网络的全连接层可完成二分类的辅助预测任务。

3.4.1 基于残差网络的 HRV 频域特征提取

本文为了比较抑郁症患者与健康对照组 HRV 之间频域指标差别，选取 50 名抑郁症患者的 ECG 数据和 50 名健康对照组的 ECG 数据进行频域特征对比分析。其中，在对每个人 ECG 数据进行预处理后，在滑动窗口的基础上对数据进行快速傅里叶变换从而进行频域特征分析，结果取均值，指标平均值见表 3-6。

可以看出，抑郁症患者的频域指标值普遍比健康对照组低，而低频高频比值较高，这可能是因为抑郁症患者脑电活动不同于健康对照组的模式，抑郁症患者的情绪波动更加明显，反应在频域指标上则普遍较低。

表 3-6 频域特征对比表

Tab. 3-6 Frequency Domain Features Comparison Table

频域指标	抑郁症患者	健康对照组
VLF	2282.7	5952.4
LF	48.9	80.3
HF	32.6	72.8
LF/HF	1.5	1.1

本文采用FFT提取HRV的频域特征。由于FFT变换处理后的HRV频域数据，形式上是一个复数矩阵，然而残差网络中的卷积层期望的输入是实数矩阵，而不是复数矩阵，无法直接应用于深度学习模型。对此，本文将经过FFT变换后的HRV复数矩阵转换为功率谱密度矩阵。功率谱密度矩阵^[63]是一个实数矩阵，表示频域信号中的能量分布，常见的计算功率谱密度矩阵的方法是将复数矩阵的每个元素乘以其共轭的转置，然后取实部。通过计算功率谱密度矩阵，将复数矩阵转换为实数矩阵，可以直接作为残差网络的输入。功率谱密度矩阵就是快速傅里叶变换取模的平方，其公式如（3-14）所示。

$$P = \lim_{T \rightarrow \infty} \frac{1}{T} \int |S(f)|^2 df \quad (3-14)$$




图 3-9 功率谱密度估计图

Fig. 3-9 Power Spectral Density Estimation Diagram

如图 3-9 所示，功率谱密度描述了信号在不同频率上的能量分布情况，可以反映出单位频率范围内信号功率的变化。横轴是频率，纵轴是能量，图中展示了在一个滑动窗口内，随着频率的增加，频率所对应的能量上升或下降的曲线图，把它作为模型的输入用于完成二分类的辅助诊断任务。

残差网络中的代表模型包括ResNet18^[64]和ResNet50^[65]。其中，ResNet18 是由 18 层组成相对较浅的模型，含有 4 个残差块；而ResNet50 包含 16 个残差块，是更深的模型。此外，ResNet-50 相较于ResNet-18 拥有更宽的层数，使用更多的卷积滤波器，提高了特征提取的能力，但也增加了计算复杂度。由于ResNet18 是相

对较轻的模型，性能良好，训练速度快，且通过残差块构建网络，更好地避免了梯度消失或爆炸问题，更好地捕获HRV频域特征，提高了分类性能。因此，本文选择ResNet18 作为抑郁症辅助诊断的主体网络模型。

在ResNet18 模型中，特征提取是在前面的卷积层主干网络部分进行的，如图 3-10 所示。




图 3-10 ResNet18 网络架构图

Fig. 3-10 ResNet18 Network Architecture Diagram

输入层通常包括一个卷积层和一个最大池化层，而中间层则是由图中虚线所示，ResNet-18 由 4 个残差块组成。每个残差块内部包含四个卷积层的堆叠，用于进一步提取图像的更高级特征，卷积层的公式如（3-15）所示：

$$Y = \partial(W * X + b) \quad (3-15)$$

Y 表示卷积层的输出特征图。 X 表示卷积层的输入特征图。 W 表示卷积核（filter）或权重矩阵。 b 表示偏置（bias）。 $*$ 表示卷积操作。 ∂ 表示激活函数（如ReLU）。卷积操作是将卷积核应用于输入特征图进行运算，以产生输出特征图。通过卷积操作，可以捕获输入特征图的空间特征，如边缘、纹理等。在卷积运算

之后，通常会引入偏置项，以实现平移不变性，从而增强模型的灵活性。激活函数被应用于卷积层的输出，以引入非线性。在最后一个残差块之后，ResNet18 使用全局平均池化层对特征图进行空间平均池化操作，将特征维度降至 $512 \times 1 \times 1$ 。前几个残差块逐渐提取图像的低级到高级特征，捕获不同层次的信息。全局平均池化层用于降维并保留关键特征信息。这样得到的特征可用于通过网络模型的最后全连接层进行分类任务。

3.4.2 HRV频域特征分类

全连接层（Fully Connected layer, FC）的功能在于特征融合。HRV特征通过卷积层和池化层之后，得到了不同抽象尺度的特征图。全连接层通过联结各个特征图中的不同特征点，将抽象特征融合综合成全局特征，以捕捉更多的图像语义信息，从而提高模型对图像的理解和区分能力。同时，全连接层同样也扮演着特征转换的角色，将输入特征映射到特定的输出维度，使得它可以与目标标签进行比较和分类。通过全连接层，模型可以对输入图像中的不同特征进行加权和组合，以生成具有更高区分性的特征表达。

如图 3-10 所示，全连接层位于ResNet18 的最后一层，其作用是将卷积层或其他类型的层输出的特征映射转换为最终的预测或分类结果。




图 3-11 ReLU函数

Fig. 3-11 ReLU Function

在ResNet18 的全连接层使用ReLU（Rectified Linear Unit）作为激活函数，如图 3-11 所示。

ReLU函数能够提供非线性映射，这种非线性映射有助于模型更好地拟合数据和学习复杂的特征表示。在全连接层中，将ReLU应用于每个神经元的输出，

可以增强网络的表达能力并提高其非线性分类能力。其公式如式（3-16）所示，当输入 x 大于0时，输出等于输入 x ；当输入 x 小于等于0时，输出等于0。

$$ReLU(x) = \begin{cases} x, & x \geq 0 \\ 0, & otherwise \end{cases} \quad (3-16)$$

在全连接层的最后一层会使用softmax函数进行二分类，Softmax函数的输出值在0到1之间表示概率的范围，函数的所有输出之和始终为1，以保证函数的输出是一个有效的概率分布。在分类时，通过Softmax函数可以放大输入向量中的差异，这意味着输入向量中较大的值将对应一个更大的概率，从而突出不同类别之间的差别。Softmax函数的公式如（3-17）所示。

$$S_i = \frac{e^{V_i}}{\sum_i^C e^{V_i}} \quad (3-17)$$

其中， V_i 是分类器前级输出单元的输出， i 表示类别索引，总的类别个数为 C ， S_i 表示的是当前元素的指数与所有元素指数和的比值。通过将输出标准化为概率分布，可以更好地进行预测，这有助于提高模型的准确性和稳定性。

综上所述，全连接层在ResNet18中起到了特征转换和分类决策的作用，它将卷积和池化后得到的特征进行进一步处理和分类，帮助模型更好地提取图像特征并做出准确的分类预测。

3.5 实验与分析

本节首先采用公开数据集SHAREE对基于HRV和残差网络的抑郁症辅助诊断模型进行实验验证。

3.5.1 数据集

本文使用的数据集来源于SHAREE的公开数据集。SHAREE的数据被划分为3类：即Class1、Class2、Class3。Class1代表专家已经作出了标注；Class2为ECG数据的原始数据；Class3则表示该数据尚处于研究中。每条数据记录包括头文件、数据文件和注释文件。其中头文件含有数据的基本属性，如记录名称、信号数量、存储格式、信号类型、采样频率、数字化特征等；数据文件以二进制形式存储了数字化采样点；注释文件记录了对信号特征的注释信息，包括心电图数据、患者基本信息等，这些信息足以满足生物医学各领域研究者的需求。本文使用的数据集总计1260例，其中抑郁症患者139例，其余为健康对照组。

抑郁症常见于青老年人群，本数据集中抑郁症患者的年龄集中在二十到三十岁，平均年龄为22.46岁。在机器学习领域为了评估算法的泛化性能，通常将数

数据集随机分成训练集和测试集。本文随机抽取其中四分之三的数据用作训练样本，剩余部分则作为测试样本。并以有无抑郁症状作为分类标签，构建一个二元分类模型。

3.5.2 实验设置与评价指标

神经网络的超参数设置如下：批量大小为 32，学习率为 0.001，采用Adam优化器进行随机梯度下降优化。每个epoch结束时，学习率以 0.7 的比例进行衰减。每次实验共进行 100 个epoch的训练。

为了验证辅助诊断抑郁症患者的模型的有效性，需要对其预测效果进行评估，本文从准确性、召回率和F1 三个性能指标对模型进行了评估。

(1) 准确率Accuracy: 针对抑郁症的存在与否进行预测的精确度可由式(3-18)得知。其中，TP代表正确预测抑郁症患者的数量，TN代表正确预测非抑郁症患者的数量，FN代表错误预测抑郁症患者的数量，FP代表错误预测非抑郁症患者的数量。

$$Accuracy = \frac{TP + TN}{TP + FN + FP + TN} \quad (3-18)$$

(2) 召回率Recall: 正确预测抑郁症患者的数量占样本集中所有抑郁症患者的比例，如表达式(3-19)所示。

$$Recall = \frac{TP}{TP + FN} \quad (3-19)$$

(3) F1 值: 是综合Accuracy和Recall两个度量指标，用于全面评估性能，其公式如(3-20)所示。

$$F1 = \frac{2 * accuracy * recall}{accuracy + recall} \quad (3-20)$$

3.5.3 实验与分析

为验证数据预处理的有效性，本研究进行了两次基于残差网络的对比实验。一次使用预处理后的数据，一次使用未经预处理的数据，实验结果见表 3-7。

表 3-7 数据预处理对比

Tab. 3-7 Data Preprocessing Comparison

数据是否处理	Accuracy/%	Recall/%	F1
预处理	82.11	80.34	0.81
未预处理	76.72	72.38	0.74

原始数据未经预处理时准确率为 76.72%，召回率为 72.38%，F1 值为 0.74；经过预处理后准确率提升至 82.11%，召回率为 80.34%，F1 值为 0.81。结果表明，数据预处理是十分必要的。

其次，为了探究不同的滑动窗口大小对实验结果的影响，本文在基 10s、20s 和 30s 窗口的基础上使用处理过的数据进行实验，实验结果见表 3-8。

表 3-8 不同窗口大小对比

Tab. 3-8 Comparison of Different Window Sizes

滑动窗口大小	Accuracy/%	Recall/%	F1
10s	74.24	68.33	0.70
20s	82.11	80.34	0.81
30s	76.53	77.83	0.76

窗口在 10s 大小时准确率为 74.24%，召回率为 68.33%，F1 值为 0.70；窗口在 20s 大小时准确率为 82.11%，召回率为 80.34%，F1 值为 0.81；窗口在 30 是大小时准确率为 76.53%，召回率为 77.83%，F1 值为 0.76。结果表明，窗口大小在 20s 时 F1 值最高，可以更好的进行特征的提取以便进行分类预测。

最后，为了研究模型的性能，将处理好的数据放入模型进行测试，测试 10 次结果取均值，结果见表 3-9。

表 3-9 基于 ResNet18 的分类预测结果

Tab. 3-9 Classification Prediction Results Based on ResNet18

测试	Accuracy/%	Recall/%	F1
平均值	82.11	80.34	0.81

十次分类预测的平均准确率为 82.11%，平均召回率为 80.34%，平均 F1 值为 0.81，该模型可以有效的进行抑郁症的辅助预测。

3.6 本章小结

本章针对原始 ECG 数据存在噪声及干扰信号的问题，首先通过巴特沃斯高通滤波器对数据进行预处理；其次，使用自适应阈值法对心电信号的 R 峰进行定位来提取 RR 间隔序列，运用滑动窗口对连续的 RR 间隔序列进行切片并进行 HRV 的时频域特征分析；最后，利用快速傅里叶变换及功率谱密度估计将特征转换成可被残差网络识别的能量图片，使用残差网络对 HRV 的频域特征进行特征向量的提取及抑郁症的辅助诊断；最后，在公开数据上模型进行实验，证明该算法模型对抑郁症的辅助诊断准确率为 82.11%，为后续多模态特征融合的辅助诊断算法研究奠定了基础。

第4章 HRV多模态特征融合技术研究

多模态融合技术^[66]通过融合多个信息源的数据,提炼不同模态数据间关联关系,可以提高对复杂问题的理解和处理能力。因此,本章研究一种基于HRV多模态特征融合的抑郁症辅助诊断技术。首先,算法模型的输入由单一频域特征扩展为时域特征和频域特征同时输入;其次,模型引入了注意力机制挖掘不同特征之间的关联关系从而提高特征融合的有效性和灵活性;最后,利用多层感知机对融合后的特征进行二分类对,实现抑郁症的辅助诊断,并通过实验验证了算法模型的有效性。

4.1 HRV时频域多模态特征融合概述

在上述研究中,由于单一特征无法全面地捕捉到抑郁症的复杂性和多样性,本文进行了改进。首先,鉴于HRV是一维时间序列,不同数值所代表的生理、心理指标和含义意义不尽相同,因此需要对HRV数值从时序上进行分析和特征提取;同时,时域和频域特征从不同角度反映了HRV信号与个体生理、心理指标的关联关系,其中,时域特征主要关注HRV的时间间隔和幅度,而频域特征则关注频率成分及其能量分布。通过整合HRV时频域特征可以更全面地描述个体生理、心理指标转台。因此,本文设计了HRV多模态特征融合的整体构建流程,如图4-1所示。

(1) 时域特征分析: 在时间维度对HRV进行时域特征分析,在一个ECG信号时长中,首先统计一个滑动窗口内的RR间隔序列,并分析其时域特性;其次,统计所有相邻的RR间隔序列,分析其在时间维度上的特性和变化规律。

(2) 时域特征提取: 对RR间隔等序列特征进行多维度统计分析,提炼HRV多维度特征作为多模态HRV融合网络的时域输入特征。

(3) 时频域特征融合: 将一个滑动窗口内的时域特征与频域特征同时作为模型的输入,并进行特征的融合,并基于融合特征实现更好的特征分类。在融合过程中,可以对时频域特征进行加权,根据其各自的重要性和贡献度来赋予不同的权重,以实现两种特征的融合。

最后,针对融合后的时频特征采用机器学习算法进行特征分类,并应用于抑郁症的辅助诊断。通过实验来验证该方法及模型的有效性,同时调整参数对模型不断进行优化和完善,以提高准确率。



图 4-1 融合特征流程图

Fig. 4-1 Fusion Feature Flow Chart

4.2 HRV时频域特征融合

HRV时域和频域特征之间存在一定的互补性。其中，时域特征更适用于描述整体的HRV情况和HRV变化幅度；频域特征更适用于分析HRV的周期性和频率特征。融合这两种特征不仅可以丰富HRV特征，而且有助于HRV的准确分类和抑郁症的辅助诊断。本节首先介绍HRV时域特征的分析提取技术，然后引入注意力机制实现HRV时频域特征的融合。

4.2.1 HRV时域特征提取

将HRV信号视为一维时间序列，时域分析主要关注于RR间隔的变化规律，通过使用统计学方法来获取信号特征，时域特征的计算方法简单明了，其数值对应的生理意义也相对清晰。常用特征包括均值(MEAN)、SDNN、RMSSD和PNN50等。

图 4-2 所示位本文随机从公开数据集中挑选一位成员的ECG数据，并随机截取其中一段ECG数据对其心跳间隔所作的时域特征分析。图中包含 300 多个心跳间隔，心跳间隔最小的有 300ms，最大的有 600 多ms。这个该段HRV数据的统计

学特征分析结果：MEAN值为480.2ms。RMSSD值为89.9(参考范围在9.4~77.5)，此RMSSD值偏大反应了被试身体对压力和恢复的适应能力偏好。SDNN的值为104.2(参考范围在18.1~105.5)，此SDNN值偏大表示被试整体HRV较高，即心率在一段时间内的变化较大，体现了交感神经和副交感神经系统的协调性良好。pNN50的值为25.6(参考范围在0.2~49.8)，此pNN50的值偏大通常表示HRV良好，即心率变化较为灵活和多样，反映出被试副交感神经系统的活动良好，适应能力较强。根据时域特征值的分析，可以预测被试为健康对照组成员。




图 4-2 心跳间隔图

Fig. 4-2 Interbeat Interval Graph

为了进一步探究抑郁症患者与健康对照组之间时域指标值的差别，本文选取50名抑郁症患者的ECG数据和50名健康对照组的ECG数据进行时域特征对比分析。对每个人ECG数据进行数据预处理后，在滑动窗口的基础上进行时域特征分析，结果取其均值，指标平均值见表4-1。

表 4-1 时域指标对比表

Tab. 4-1 Time-domain Indexes Comparison Table

时域指标	抑郁症患者	健康对照组
SDNN	52.8	92.5
RMSSD	43.5	68.6
PNN50	31.4	44.3

可以看出，抑郁症患者的时域指标值普遍低于健康对照组，这是因为抑郁症患者存在情绪调节困难等问题，表现出更少的大脑电活动，从而导致指标值普遍偏低。对抑郁症患者及健康对照组的时域特征对比分析后，将统计好的时域值作为模型的输入进行时频域特征的融合。

4.2.2 基于注意力机制的HRV时频域特征融合

基于注意力机制的HRV时频域特征融合过程如图4-3所示。首先，将上面经过ResNet层生成的频域特征向量和经过统计得到的时域特征向量共同作为注意力算法模型的输入；然后，利用评分函数计算向量 q 与每个输入向量之间的相关

性，生成一个分数，分数高则权重大，最后通过concatenate函数对特征向量进行拼接，注意力机制的基本公式如（4-1）所示。

$$Attention(q, K, V) = softmax\left(\frac{qK^T}{\sqrt{d_k}}\right)V \quad (4-1)$$

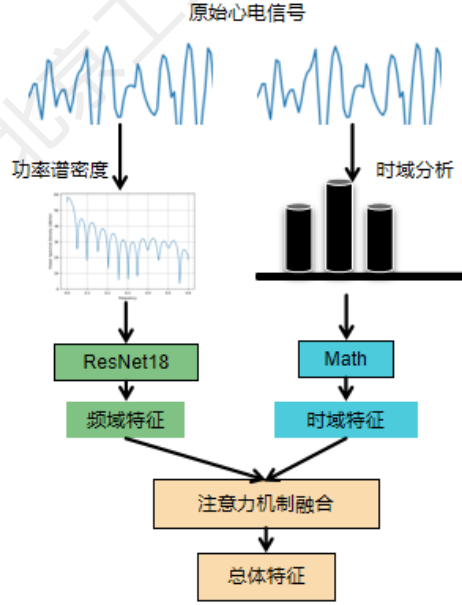


图 4-3 特征融合图

Fig. 4-3 Feature Fusion Graph

q 是查询向量(query vector)，表示当前位置的注意力的关注点； K 是键(key)矩阵，表示与查询向量相关的数据关键信息； V 是数值(value)矩阵，表示根据查询和键计算得到的数值信息； d_k 是键的维度。softmax是激活函数，用于计算注意力权重，将其转换为概率分布，其公式如（4-2）所示。

$$softmax = \frac{\exp(s(h_i, q))}{\sum_{j=1}^n \exp(s(h_j, q))} \quad (4-2)$$

模型的特征输入为 $H = [h_1, h_2, h_3, \dots, h_n]$ ，在应用注意力机制进行内容计算时，一般需要查询向量 q 。然后，通过评分函数计算查询向量 q 与每个特征输入 h_i 的关联性，并获得对应的得分。接下来，使用softmax函数对这些得分进行归一化处理。

其中，打分函数如公式（4-3）所示。

$$f(x) = \sum_{i=1}^n \alpha(x, x_i) y_i \quad (4-3)$$

其中 x 为查询, x_i 为键, y_i 为键对应的值, 查询 x 和 x_i 之间的注意力权重为 $\alpha(x, x_i)$, 如果一个键 x_i 越接近给定的查询 x , 那么分配给这个键所对应的值 y_i 的注意力权重也就越大, concatenate函数如公式(4-4)所示。

$$C = \text{Concat}(A, B, \text{axis} = k) \quad (4-4)$$

有时域特征向量 A 和频域特征向量 B , 它们的形状分别为 $\text{shape}_A = (d_1, d_2 \dots d_n)$ 和 $\text{shape}_B = (d_1, d_2 \dots d_m)$, 进行在第 k 维度上的拼接操作, 得到新的张量 C , 形状为 $\text{shape}_C = (d_1, d_2 \dots d_k, \dots d_n, d_m)$ 。Concatenation 操作是一种向量拼接的结合方法, 它不改变张量的形状而是在指定的维度上对向量进行加权连接得到融合向量。通过Concatenation操作, 不同来源的时频域特征可以被有效地整合和传递, 进而提高深度学习模型的表达能力和性能。

注意力机制可以帮助系统自动学习和筛选出HRV信号中最重要的特征, 从而实现更有效的特征融合。通过引入注意力机制, 系统可以自动调节HRV时域和频域特征的权重, 使得重要的特征得到更多的关注, 提高了特征融合的效果。

4.3 基于HRV多模态特征融合的抑郁症辅助诊断技术

本节介绍了一种基于多模态特征融合的抑郁症辅助诊断模型。该模型结合了改进后的ResNet18、注意力机制以及多层感知机技术, 充分考虑了心率变异性的时频域特征。通过注意力机制筛选出对抑郁症预测任务关键的特征, 最后通过多层感知机网络实现抑郁症的辅助诊断。

4.3.1 多模态特征融合网络架构

基于多模态特征融合的抑郁症辅助诊断模型的整体网络架构如图 4-4 所示。

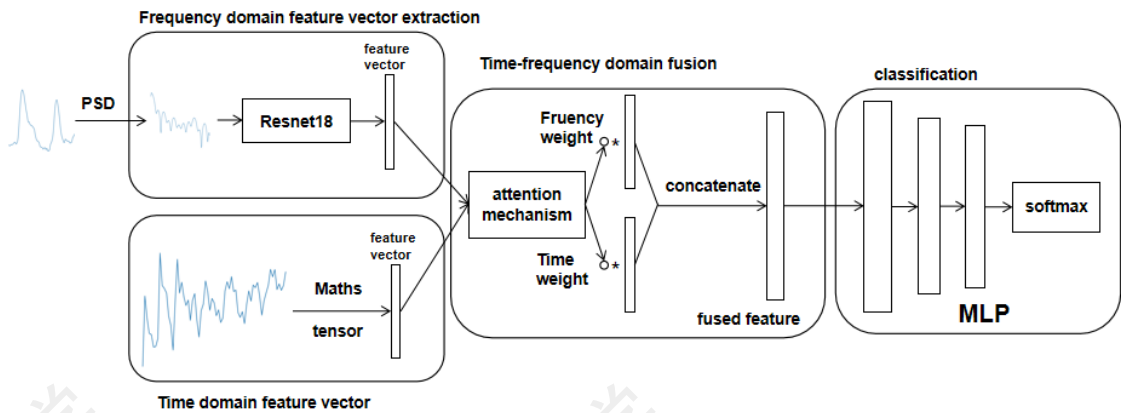


图 4-4 抑郁症辅助诊断架构

Fig. 4-4 architecture for assisting in the diagnosis of depression

其中，该模型的第一部分涉及时域特征和频域特征向量的提取。频域特征向量通过改进后的ResNet18进行提取，改进后的ResNet18网络结构如图4-5所示。




图 4-5 改进后的ResNet18 网络架构

Fig. 4-5 Improved ResNet18 Network Architecture

改进后的ResNet18 模型包含 4 个残差块，共计 17 个卷积层和 2 个池化层。输入为经过PSD变换后生成的 $224 \times 224 \times 3$ 维度的图像。首先经过一个步长为 2 的 7×7 大小的卷积层，然后是一个尺寸为 3×3 ，步长为 2 的最大池化层，将图像转换为 $56 \times 56 \times 64$ 的特征向量。接着是四个残差块，每个残差块包含如图 4-5 中虚线所示的两个残差单元，每个残差单元包含两个卷积层。其中第一个残差块的卷积核大小为 3×3 ，步长为 1，padding 为 1，输出通道为 64；第二个残差块的卷积核大小为 3×3 ，第一个卷积层步长为 2，其余卷积层步长为 1，padding 为 1；第三和第四个残差块的卷积核大小都是 3×3 ，第一个卷积层步长为 2 其余为 1，padding 为 1。通过中间层，图像转换为 $512 \times 7 \times 7$ 的特征向量。最后经过一个平均池化层将输出向量转化为 $512 \times 1 \times 1$ 大小。

通过从心电信号中获取的RR间隔序列，采用滑动窗口技术分别计算了RR间隔序列的RMSSD、SDNN、PNN50 等时域特征，最后生成大小为 $3 \times 1 \times 1$ 的时域特征向量。

该模型的第二部分涉及时频域特征向量的融合。首先，将时域向量展平为一个长度为 3 的一维向量，将一维向量与一个 512×3 的矩阵进行乘法操作，从而得到 $512 \times 1 \times 1$ 的时域向量，扩展到与频域向量相同的维度；其次，计算时域向量和频域向量之间注意力分数，将得到的注意力分数经过softmax函数进行归一化处理，保证注意力权重的总和为 1；最后，将归一化后的注意力权重与时频

域向量进行加权求和，最终生成了 $512 \times 1 \times 1$ 的总体特征向量，供后续抑郁症的辅助预测使用。

4.3.2 基于多层感知机的辅助诊断层

本文采用多层感知机（MLP）进行特征学习和分类，进而依据多模态HRV特征实现抑郁症辅助诊断。多层感知机模型如图 4-6 所示。




图 4-6 多层感知机

Fig. 4-6 Multilayer Perceptron

数据通过MLP网络从输入层传递到输出层，每个神经元都应用激活函数，该激活函数如式（4-5）所示。

$$\tanh = \frac{e^x - e^{-x}}{e^x + e^{-x}} \quad (4-5)$$

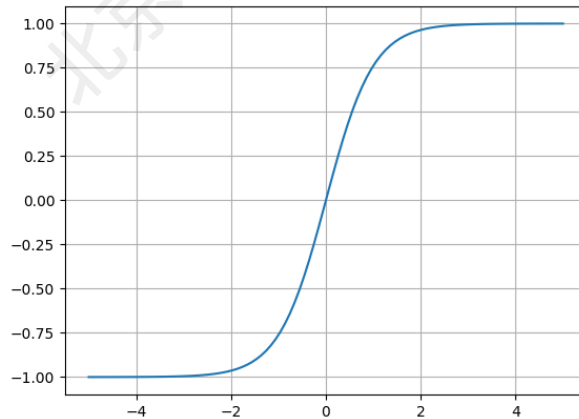


图 4-7 tanh函数

Fig. 4-7 Tanh Function

如图 4-7 所示，该公式为双曲正切函数，具有将输入值映射到范围 $(-1, 1)$ 内的特性。即当输入 x 趋向于无穷大时， $\tanh(x)$ 趋近于 1；当 x 趋向于负无穷小时， $\tanh(x)$ 趋近于 -1；当 x 等于 0 时， $\tanh(x)$ 等于 0。

$\tanh(x)$ 函数是关于原点 $(0,0)$ 对称的函数,即满足 $\tanh(-x) = -\tanh(x)$ 。 \tanh 函数在原点附近斜率较大,当输入较大或较小时,梯度会逼近于 0。这种性质使得 \tanh 函数相较于sigmoid函数来说,对平均为 0 的数据更具有优势,可以减缓梯度消失问题。具有输出范围广、对称性、梯度较大等特点,适合用于神经网络中,特别是网络层中需要将输出值限制在一定范围内的情况下。

在常见的分类器任务中,多层感知机最常采用交叉熵损失函数,对于多类别分类任务,交叉熵损失函数可以用来衡量模型预测的概率分布与真实标签之间的差异。其数学形式通常为负对数似然损失,可以用来衡量模型对每个类别的预测概率与真实类别的匹配程度。通过最小化交叉熵损失函数,可以使得模型的预测更加接近真实情况,从而提高分类的准确性,其公式如(4-6)所示。

$$L = - \sum_{i=1}^n p(x_i) \log(q(x_i)) \quad (4-6)$$

其中, n 为类别数量, $p(x_i)$ 为符号函数,如果训练样本的真实类别为 i 则取 1,否则取 0。 $q(x_i)$ 为神经网络预测样本属于第 i 类的概率。 L 为损失值。

本文采用了最大化似然估计来作为损失函数。其数学表达式如(4-7)所示。

$$J(W) = -E_{x,y \sim p_{data}} \log p_{model}(y|x) \quad (4-7)$$

其中, J 为损失值, W 为待训练的参数, y 为训练样本的目标, x 为输入。

反向传播是神经网络中的一种优化算法,通过计算损失函数对每个参数的梯度,从而实现参数更新的过程。其目的是在参数空间中寻找使损失函数最小化的点,从而提高模型对数据的拟合效果。通过不断迭代更新参数,使得模型能够更准确地预测输出结果,提高模型的性能和泛化能力,其公式如(4-8)所示,迭代地更新梯度,最终找到损失函数的最小值。

$$Y = W - \theta \nabla_w L \quad (4-8)$$

其中 W 表示更新前的参数, Y 表示更新后的参数, θ 表示学习率。设置合适的学习率可以加快收敛速度,从而减少训练的迭代次数。

在多层感知机的最后一层本文采用sigmoid函数来进行二分类,如图 4-8 所示。

函数将输出映射到 0 和 1 之间,表示分类样本属于正类的概率。这样的设计使得模型可以输出样本属于正类的概率值,从而进行二分类任务的预测,其公式如(4-9)所示。

$$S(x) = \frac{1}{1 + e^{-x}} \quad (4-9)$$

其中 x 表示输入， e 表示自然对数的底， $S(x)$ 表示函数的输出。Sigmoid函数在 $x=0$ 处是中心对称的，这意味着当输入趋近于正无穷或负无穷时，函数的输出接近于1或0。这使得Sigmoid函数可以将较大或较小的输入映射到接近极端的输出值，从而实现对输入数据的压缩和约束。由于Sigmoid函数的输出在0到1之间，并且有良好的概率解释，因此本文将用于抑郁症的二分类问题，以表示某个样本属于正类的概率。




图 4-8 Sigmoid函数

Fig. 4-8 Sigmoid Function

激活函数、损失函数以及分类函数的建立已经完成，激活函数用于引入非线性变换，损失函数用于衡量模型输出与真实标签之间的差异，而分类函数则用于将模型的输出映射到具体的类别或概率分布。完成这些函数的建立后，还需要通过优化算法对神经网络模型进行训练，以不断调整参数使得模型的输出更加接近真实情况，从而提高模型的性能。整个过程需要不断迭代和调优，直到达到预期的性能水平为止。

4.4 实验与分析

本节采用公开数据集SHAREE实验分析验证基于HRV多模态融合的抑郁症辅助诊断算法模型的有效性。实验环境及数据集选择3.5章节相同。

首先为了验证注意力机制与向量直接加权拼接哪个方式可以更好地进行特征融合，本文进行实验结果见表4-2。

时频域特征向量直接加权拼接时的准确率为72.34%，召回率为77.21%，F1值为0.74，直接使用加权拼接造成原有的特征提取不明确，也无法进行合适的特征融合，所以造成准确率、召回率和F1值比单一特征预测时较低。使用注意力机制进行向量融合时准确率为86.82%，召回率为84.28%，F1值为0.85，可以得出

在特征融合方面，注意力机制比直接加权拼接有更好的F1 值，注意力机制使得重要的特征得到更多的关注，提高了特征融合的效果。

表 4-2 向量融合不同方式对比

Tab. 4-2 Comparison of Vector Fusion in Different Ways

不同融合方式	Accuracy/%	Recall/%	F1
直接加权拼接	72.34	77.21	0.74
注意力机制	86.82	84.28	0.85

其次为了验证模型的性能，将多模态特征作为模型的输入进行测试，测试 10 次结果取均值，结果见表 4-3。

表 4-3 基于多模态特征的分类预测结果

Tab. 4-3 Classification Prediction Results Based on Multimodal Data

测试	Accuracy/%	Recall/%	F1
平均值	87.46	84.21	0.85

10 次分类预测的平均准确率为 87.46%，平均召回率为 84.21%，平均F1 值为 0.85，可以看出模型在处理多模态特征时表现良好，具有更高的分类准确性和稳定性。

最后，为了验证本文提出的网络模型的有效性，将模型与KNN、Bayes、Logistic、CNN算法进行对比。在K-NN算法中，设定k值为 2；贝叶斯算法则基于条件概率进行事件发生后的概率推断；Logistic分类是有监督学习，需要人工标注数据；CNN为传统的卷积神经网络。所有算法均采用相同的数据集、相同的训练和测试长度，运行 10 次后取平均性能评估，结果如表 4-4 所示。

表 4-4 不同算法预测结果

Tab. 4-4 Different Algorithms Predict Results

分类算法	Accuracy/%	Recall/%	F1
KNN ^[67]	79.84	77.21	0.79
Bayes ^[68]	49.44	39.28	0.44
Logistic ^[69]	76.92	80.42	0.77
CNN	80.64	78.38	0.79
ResNet18	82.11	80.34	0.81
改进ResNet18	87.46	84.21	0.85

可以看出，Bayes算法均值明显低于其他 4 中算法，可能由于贝叶斯定律对模型的特征具有很强的独立性，没有考虑到特征之间的联系。KNN、Logistic、CNN算法平均准确率都在 76.92~80%左右。而本文提出的模型平均准确率最高在 87%左右，且F1 值也最高为 0.85。从结果上看，准确率、召回率等指标都远

远超过了所对比的模型，也进一步说明了本文提出的融合数值图像多模态的抑郁症辅助诊断模型的优越性。

4.5 本章小结

本章介绍了一种基于多模态特征融合的抑郁症辅助诊断技术。首先，通过统计学方法获取了心率变异性的时域特征，并将其与ResNet18提取的HRV频域特征结合作为模型的输入。其次，利用注意力机制实现了对HRV时域和频域特征的融合，以突出重要特征。最后，采用多层感知机进行抑郁症的辅助诊断。实验结果表明，该方法相较于其他辅助诊断方法具有更好的分类性能，同时也验证了多模态输入相较于单一频域特征输入具有更高的准确率。

第5章 面向抑郁症辅助诊断系统的分析与设计

本章采用面向对象方法对抑郁症辅助诊断系统进行需求分析来获得系统的功能性、非功能性需求,并进行架构设计、详细设计和数据库表设计。

5.1 需求分析

抑郁症辅助诊断系统旨在为专业医护人员提供全面的服务。除了记录患者的基本信息外,系统还支持导入患者的心电数据,通过对心电数据的分析,输出疾病诊断和预测结果。此外,系统还提供患者心电数据的管理、组织管理、患者出入院管理以及日志查询等功能,以帮助医护人员更有效地诊断和治疗抑郁症患者。

5.1.1 功能性分析

抑郁症辅助诊断系统专为医生辅助诊断抑郁症而设计开发。系统的主要功能包括患者心电数据的采集和保存,患者心率变异性特征分析,以及抑郁症风险的预测。此外,系统支持不同角色的用户,每种角色拥有不同的功能权限,以满足医护人员的各种需求。

(一) 医生的用例分析

系统提供了如图 5-1 所示的服务,其中包括登录注册、辅助诊断以及患者管理等功能。医生在登录时需要选择身份,并输入用户名和密码,仅在验证通过后方可进入系统。系统为医生提供辅助诊断服务,包括疾病分析结果和风险预测结果的输出,并且支持对患者所属的组织进行调整和管理。

(1) 登录注册

在登录注册模块中,当有新医生入职时,需进行新账号的注册。登录时,必须正确填写账号名称及密码,密码必须与账号匹配。若密码错误次数超过 3 次,则会导致账号被锁定。

(2) 疾病的辅助诊断

在疾病的辅助诊断模块中,针对患者采集的心电图数据,系统将根据心电数据进行HRV特征分析并且给出风险评估结果。

(3) 组织、患者管理

在组织、患者管理模块中,医生可以进行组织架构的调整,如在部门内人员过多时,可新建一个组来管理患者。医生也可以查看已建档患者信息,并记录患者的出院和住院情况。

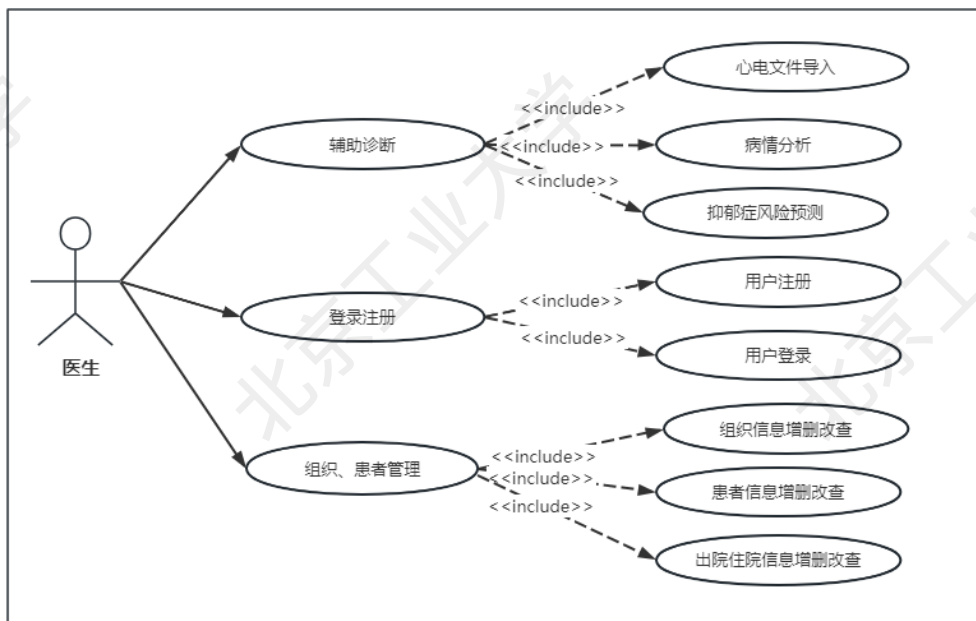


图 5-1 医生用例图

Fig. 5-1 Doctor Use Case Diagram

（二）患者的用例分析

系统提供了如图 5-2 所示的服务，包括患者注册、病情跟踪和信息修改等功能。

（1）病情管理

抑郁症患者在就诊时，需要先采集 ECG 数据作为后续治疗的依据，并进行心率变异性的特征分析。医生可以查看心率变异性分析结果和辅助诊断结果，并查看患者的就诊记录和诊断历史。患者的信息发生变化时，可以及时修改以便医生查阅和及时就诊。

（三）管理员的用例分析

系统管理员主要职责包括管理患者、医生，以及进行自身的登录操作，具体内容如图 5-3 所示。

（1）患者管理

在患者管理模块中，当患者忘记密码时或者重试次数过多导致账户锁定时，经验证身份后，可进行密码的重置。

（2）医生管理

在医生管理模块中，当医生忘记密码或者重试次数过多导致账户锁定，经过身份验证后可以进行密码的重置。

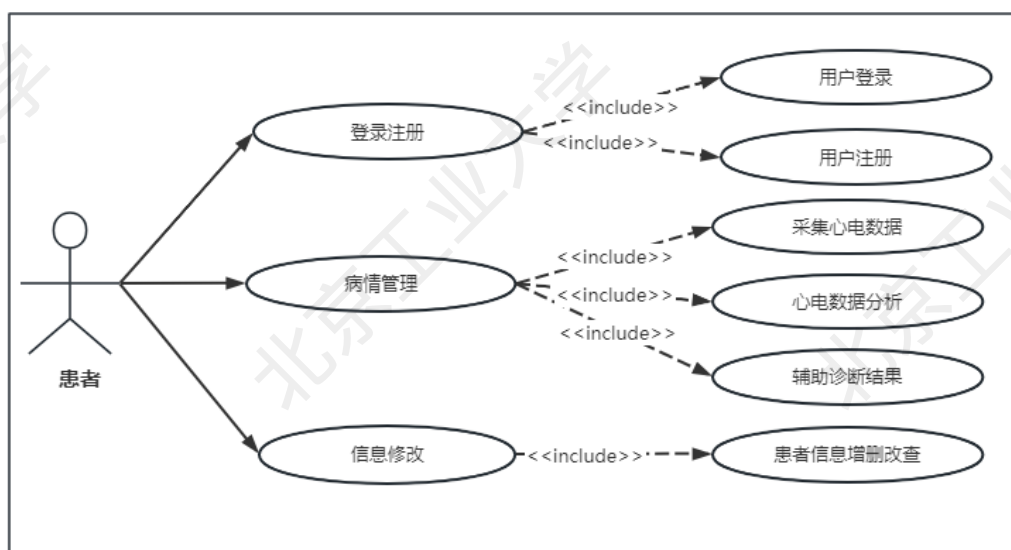


图 5-2 患者用例图

Fig. 5-2 Patient Use Case Diagram

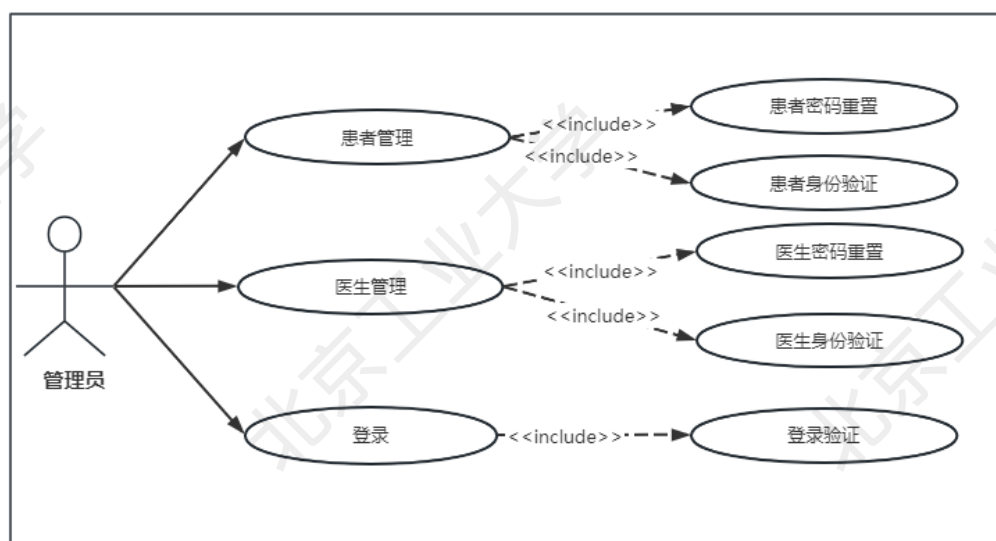


图 5-3 管理员用例图

Fig. 5-3 Administrator Use Case Diagram

5.1.2 非功能性分析

在软件开发过程中还需要认真分析非功能性需求。包括系统的稳定性、保密性等多个方面。

(1) 可靠性

为了确保患者的健康和生命安全，系统必须提高抑郁症识别的准确率至少达到 87%，从而减少误诊和漏诊的情况。

（2）安全性

为了保障患者的隐私和数据安全，系统必须在数据传输过程中采用 256 位 SSL 加密措施。

（3）可用性

为了确保医生能够方便地进行诊断和治疗，系统应确保用户界面响应时间在 1 秒以内，以提供卓越的软件体验，使操作更加流畅和便捷，确保医生工作的效率。

（4）性能

为了提高工作效率，系统应能够快速处理医生的查询和操作请求，保持每小时诊断请求不少于 100 个的吞吐量，并确保响应时间在 1 秒以内，高性能的服务能够提升用户对系统的依赖度。

（5）可扩展性

为了满足医生和患者的需求，系统应具备良好的灵活性和可定制性，能够适应不同规模和复杂度的医疗场景，并支持每月 10% 的增长，确保系统具备良好的扩展性。

（6）易用性

医生使用系统时，应能够迅速了解系统功能，以便有效地对患者进行诊断和后续的治疗。

（7）可移植性

为了确保系统的无缝转移和共享，它需要具备良好的可移植性，可以在各种不同的操作系统和硬件平台上运行。系统还应当支持多种数据库和数据格式的兼容性，以满足不同环境下的需求。

5.2 系统设计

本节将对抑郁症辅助诊断系统进行系统设计，这是一个非常重要的步骤，系统的设计直接影响到后续的开发和实施。首先，将详细讨论系统的架构设计，包括系统的整体结构以及各个模块之间的关系和交互。接着，深入到系统的详细设计，考虑到用户的需求和系统的功能，设计出具体的功能模块图。同时，系统开发过程中涉及到的数据库表设计也是至关重要的一部分，需要考虑到数据的存储

和管理，确保系统的稳定性和可靠性。因此，在设计过程中，要充分考虑到各个方面的需求和限制，确保最终的系统能够满足用户的需求并达到预期的效果。

5.2.1 系统架构设计

在上节需求分析基础上，本文采用分层与分区结合的思想设计了面向抑郁症辅助诊断的系统架构。如图 5-4 所示，系统的总体架构从上到下分为：前端UI层、业务逻辑层、数据层和运行环境层。在设计过程中，注重各层之间的协同作用，以确保系统的高效运行和用户体验。

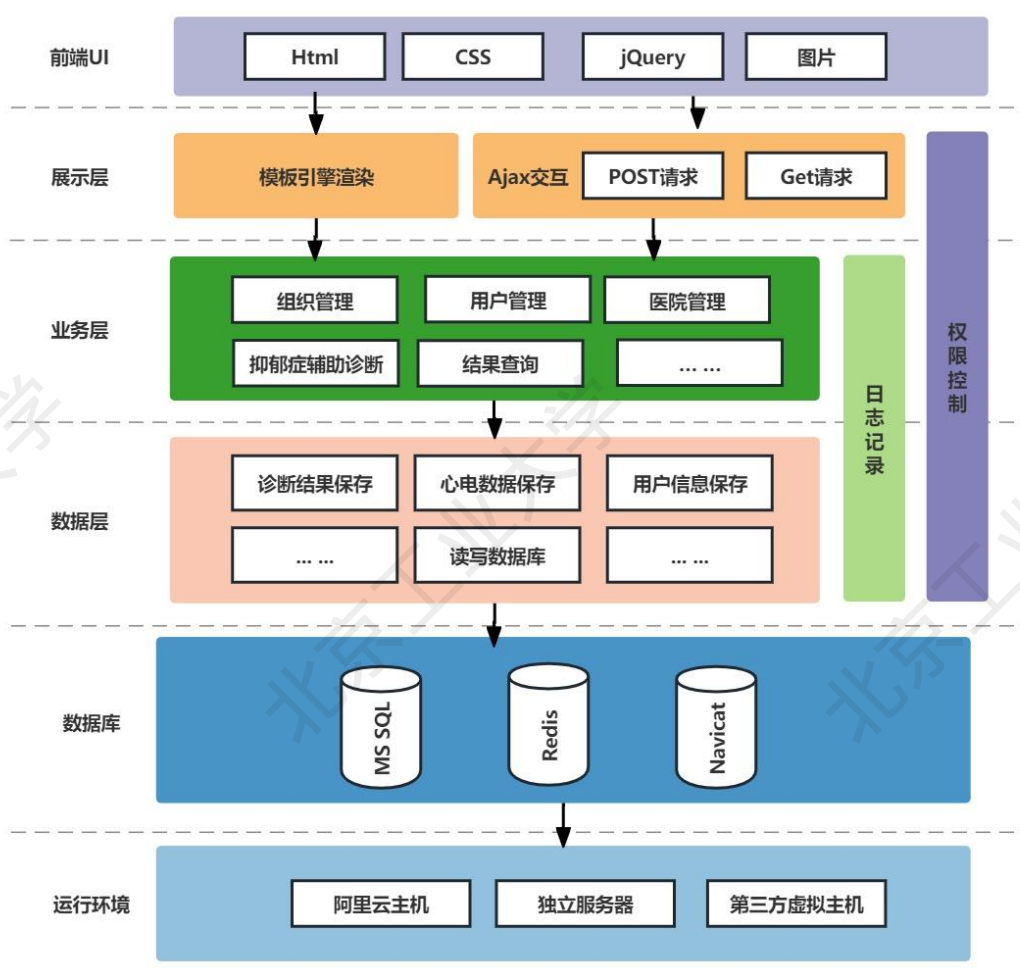


图 5-4 系统架构图

Fig. 5-4 System Architecture Diagram

(1) 前端UI层（User Interface Layer）：该层着重考虑医生与用户的交互体验。这包括设计侧边栏以及每个侧边栏所对应的主界面，确保排版和样式符合大

众喜好。同时，也要确保主界面中的功能能够满足医生的需求，例如患者管理和组织架构的调整。

(2) 业务逻辑层 (Application Logic Layer)：在图 5-5 所示的时序图中，这一层的关键职责主要包括实现系统登录和抑郁症的辅助诊断。首先，它负责采集 ECG 数据，并对这些数据进行特征分析，以便有效地识别出潜在的抑郁症迹象。这项任务需要结合专业的医学知识和先进的数据分析技术，以确保诊断的准确性和可靠性。通过对 ECG 数据的分析，系统可以提供有力的支持，帮助医生更好地进行抑郁症的诊断和治疗。除了抑郁症的辅助诊断，这一层还承担着实现系统的非核心功能的责任。其中包括算法逻辑判断、异常处理和日志打印等任务。算法逻辑判断涉及到系统在运行过程中对各种数据和条件的处理和判断，以确保系统能够按照预期的逻辑进行运行。异常处理是指在系统发生异常情况时，对异常情况进行捕获和处理，以防止系统因异常而崩溃或运行出现严重问题。日志打印则是记录系统运行过程中的关键信息和事件，为系统的监控和故障排查提供必要的技术支持。

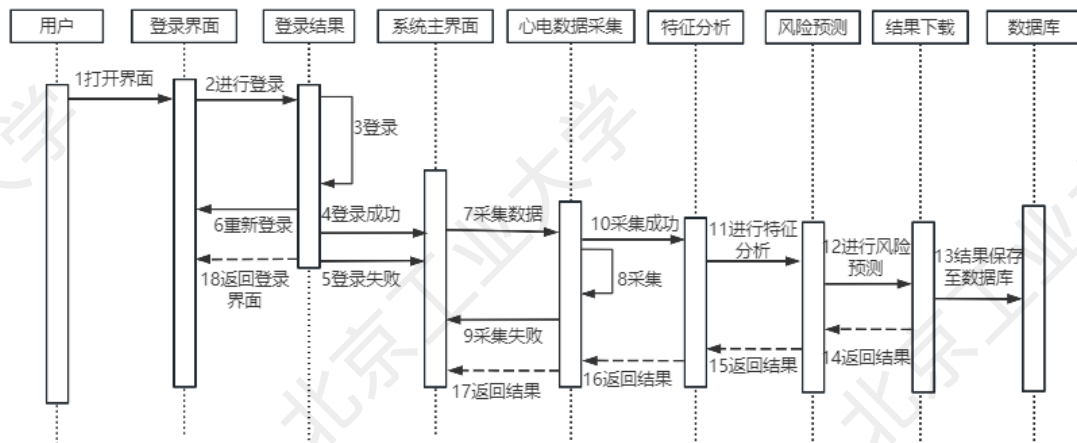


图 5-5 系统时序图

Fi. 5-5 System timing diagram

(3) 数据层 (Data Access Layer)：是系统的核心，主要职责是管理和存取数据。这包括用户信息、患者 ECG 数据、数据分析结果以及辅助诊断结果的存储。同时，数据层也需要支持结果的下载功能，以便医生和用户能够方便地获取和分享诊断结果。在设计数据层时，要注重数据的安全性和可靠性，确保用户信息和诊断结果的保密性和完整性。

(4) 运行环境层 (Infrastructure Layer)：这一层负责支撑系统的基础架构和技术支持，这一层在整个系统中担负着至关重要的责任，其任务旨在支持系统的基础架构和提供必要的技术支持。作为系统的基础，它的稳定性和可靠性直接

影响着整个系统的运行效率和安全性。基础架构的搭建需要考虑到系统的规模、性能需求以及未来的扩展性，因此这一层的工作需要精心策划和周密设计。

总体来说，本架构设计为系统高质量运行提供了基础，使各个层次做到了高内聚低耦合，且各个层次协同合作提高了系统运行效率。

5.2.2 系统详细设计

如图 5-6 所示，基于 5.1 节系统的功能性和非功能性需求分析，本文对抑郁症辅助诊断系统进行了功能模块划分。系统包含了医生模块、患者模块、辅助诊断模块以及系统管理模块。

(1) 医生模块

该模块主要用于医生管理患者信息，包括患者的出入院记录以及隶属于哪个组织下的哪个小组。一个小组可以包含多个患者，而一个患者只能属于一个小组。这种组织结构有助于医生更好地管理患者信息，确保每个患者都能得到适当的关注和治疗。

(2) 患者模块

模块主要为患者提供方便的自我就诊记录查询功能。它包括每次就诊时的 ECG 数据采集、每次就诊所产生的记录查询(包括时间、主治医生、地点等信息)，以及每次就诊产生的结果可视化。通过结果的可视化对比，患者可以查看诊断是否有效。这样的功能设计能够帮助患者更好地了解自己的就诊情况，并及时跟进治疗进展。

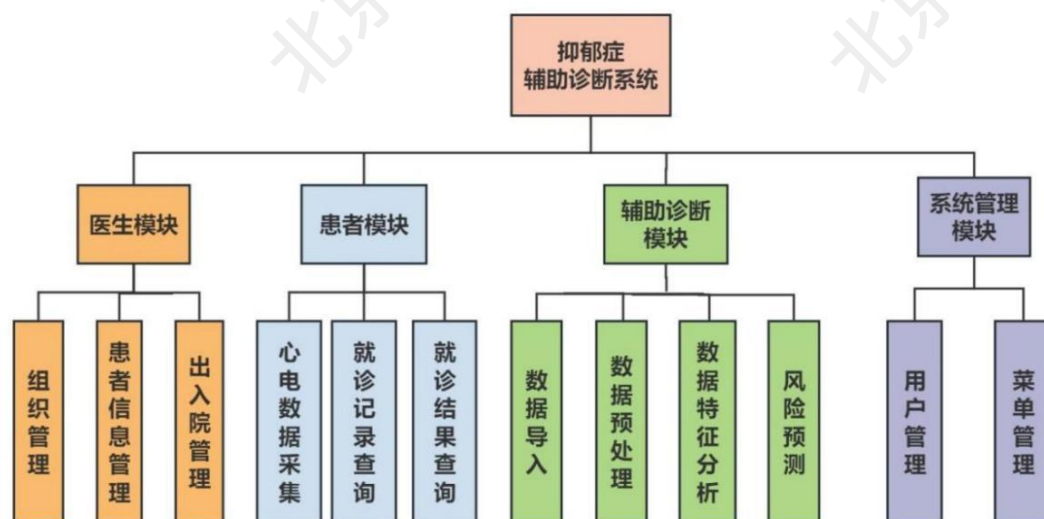


图 5-6 抑郁症辅助诊断系统功能模块图

Fig. 5-6 Depression Auxiliary Diagnosis System Functional Module Diagram

(3) 辅助诊断模块

医生可以输入患者的基本信息并导入患者的ECG数据文件，系统会根据导入的ECG数据进行特征分析和抑郁症的风险预测，然后提供相应的病情分析结果和预测结果。辅助诊断模块主要包括ECG数据的导入、预处理、结果分析以及抑郁症风险预测四个功能。这些功能有助于医生更准确地评估患者的病情和风险，并为治疗提供更有效的指导。

(4) 系统管理模块

主要包括用户管理和菜单管理两大功能模块。用户管理模块致力于管理系统中的用户信息，包括但不限于用户的注册、登录、密码重置和删除等功能。通过这一模块，管理员可以轻松管理系统用户，确保用户信息的安全和完整性。密码重置功能允许用户在忘记密码时通过一系列验证步骤重新设置密码，保障用户账户的安全性。同时，管理员也可通过该模块对用户账户进行删除等操作，以维护系统的规范性和安全性。菜单管理模块则主要负责系统导航栏的管理和配置。管理员可以通过该模块对系统导航栏进行新增、编辑和删除等操作，实现对系统功能和页面的灵活管理。通过日志查看功能，管理员可以随时监控系统的操作日志，了解用户的操作行为和系统的运行情况，及时发现并解决潜在问题。导航栏新增服务则提供了一种便捷的方式，使管理员能够快速地为系统新增导航栏项，提升系统的易用性和用户体验。通过这些功能，管理员能够有效地管理系统用户，维护系统的安全和稳定运行，并且灵活地配置系统导航栏，提升用户的操作便捷性和体验感。

5.2.3 数据库表设计

这个系统的类模型如图 5-7 所示，主要由 5 个类组成：用户类、医院类、诊断信息类、诊断结果类和出入院记录类。它们之间的依赖关系如下。用户类用于存储用户（包括医生和患者）的基本信息；医院类用于描述医院的信息，可能包括医院的名称、地址等；诊断信息类用于存储诊断过程中的信息，如就诊时间、主治医生、诊断地点等；诊断结果类依赖于用户类和诊断信息类，存储具体的诊断结果，可能包括病情分析、预测结果等；出入院记录类用于记录患者的出入院信息，包括入院时间、出院时间等。用户类和诊断信息类之间存在依赖关系，因为需要将诊断信息关联到特定的用户（患者或医生）；诊断结果类依赖于用户类和诊断信息类，因为诊断结果需要关联到特定的用户和特定的诊断信息；出入院记录类依赖于用户类，以标识患者的出入院状态。这种类之间的依赖关系有助于系统在进行信息存储和查询时保持数据的一致性和完整性。

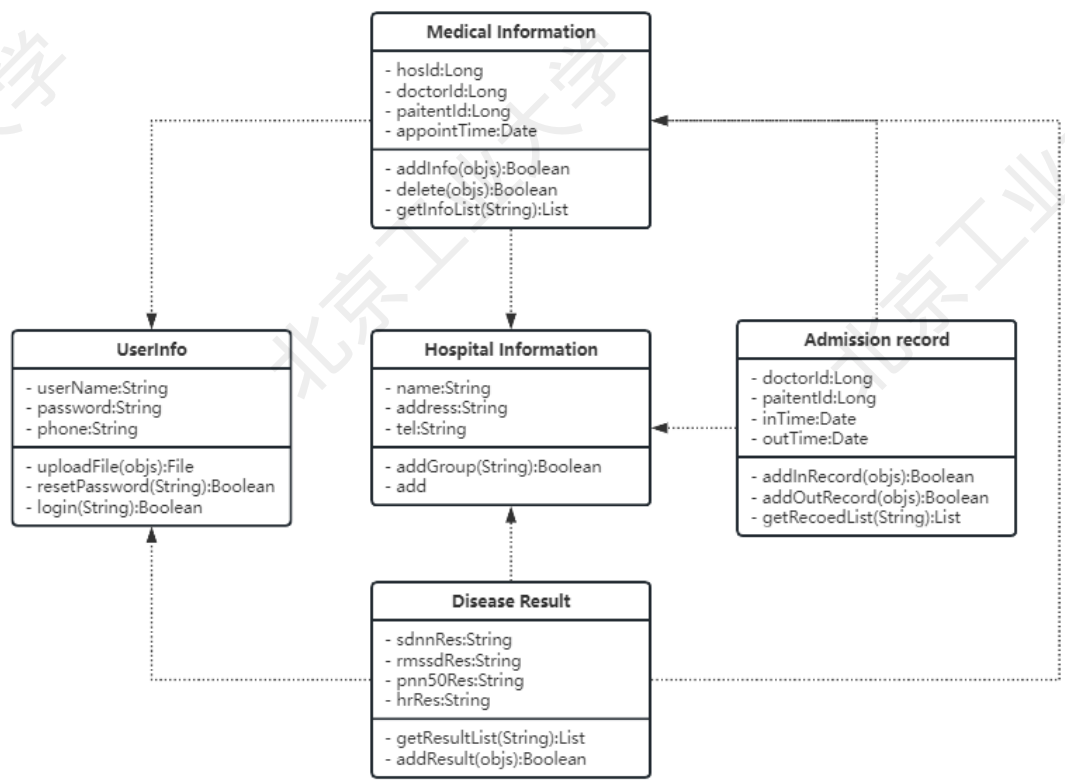


图 5-7 系统类图

Fig. 5-7 System Class Diagram

接着根据该系统的模块设计，设计了以下的数据库表：用户表、医院表、就诊结果表、就诊信息表、出入院记录表等。下面是系统开发时涉及到的关键实体的数据库表结构。

(1) 用户表

表 5-1 展示了数据库表行数据的主键，自增ID，以及用户登录所需的用户名和密码。为了确保安全性，密码在存储到数据库之前必须进行加密，以防止密码泄露的风险。如果用户是医生，表中还包括医生的工号，所在医院和科室的主键或名称。如果用户是患者，则字段还包括就诊卡号，因为患者需要就诊卡才能在医院进行就诊，而且就诊卡号必须是唯一的，不能重复。此外，表中还包括共同的字段，如联系电话和用户身份类型等。用户登录时可以选择是医生还是患者，系统将根据用户选择的身份与数据库中存储的类型进行比对，只有校验成功才能登录并访问资源。需要注意的是，密码加密是保护用户隐私和数据安全的重要措施之一。同时，就诊卡号的唯一性保证了患者在医院就诊时的准确识别，避免了身份混淆和数据冲突的可能性。

表 5-1 用户信息表

Tab. 5-1 Userinfo Table

字段名称	数据类型	长度	约束	备注
id	int	30	key, not null	自增主键
user_name	varchar	40	not null	用户名
password	varchar	40	not null	用户密码
tel	varchar	21	not null	手机号
dot_num	varchar	12	not null	医生工号
id_num	varchar	12	not null	就诊卡卡号
hos_id	int	12	not null	所在医院主键
dept_name	varchar	30	not null	所在科室名称
type	tinyint	1	not null	1 表示医生, 0 表示患者

(2) 就诊信息表

在表 5-2 中, 展示了就诊信息表用于记录患者就医时产生的相关数据。每行数据包括唯一标识符ID、患者所在医院的ID、患者的个人标识符、所选医生的标识符、患者的基本信息(如电话、姓名)以及就诊时间和结果。这些数据存储在数据库中, 诊断辅助模块可以利用这些信息提供患者的详细就医情况, 为医生提供更好的诊断支持。医疗信息表在医疗系统中扮演着重要角色, 它有效记录了患者的就医历史和治疗过程, 为医护人员提供及时准确的信息支持。这些表的设计和管理对于医疗信息系统的正常运行和数据安全至关重要。

表 5-2 就诊信息表

Tab. 5-2 Medical Information Table

字段名	数据类型	长度	约束	备注
id	int	20	key, not null	自增主键
hos_id	int	20	not null	就诊医院主键
doc_id	int	20	not null	医生主键
pat_id	int	20	not null	患者主键
pat_name	varchar	20	not null	患者名称
appointment_date	date	20	not null	患者就诊的时间
file	varchar	255	not null	文件保存地址

(3) 就诊结果表

表 5-3 则展示了就诊结果表, 用于存储患者就诊时产生的结果信息。该表包括患者ID作为外键, 以确保结果与特定患者相关联。此外, 表中还包括时域特征和频域特征的结果值。通过数据可视化, 此表可以为医生辅助诊断提供直接帮助。就诊结果表是医疗信息系统的关键组成部分, 记录了患者就医过程中产生的各种

结果数据，对于医生进行诊断和治疗决策至关重要。通过分析就诊结果表中的数据，医生可以更好地了解患者的病情和治疗效果，为患者提供更精准的医疗服务。

表 5-3 就诊结果表

Tab. 5-3 Disease Result Table

字段名	数据类型	长度	约束	备注
id	int	20	key, not null	自增主键
patient_id	Long	8	not null	患者主键
sdnn_res	varchar	20	not null	间隔标准差
rmssd_res	varchar	255	not null	间隔均方根
pnn50_res	varchar	20	not null	超过 50ms 占比
hr_res	varchar	20	not null	心率
tp_res	varchar	20	not null	总能量
vlf_res	varchar	20	not null	极低频
lf_res	varchar	20	not null	低频
hf_res	varchar	20	not null	高频
lf/hf_res	varchar	20	not null	低频高频比

5.3 本章小结

本章针对抑郁症的辅助诊断系统进行了深入的需求分析和系统设计。其中，在系统分析阶段系统地分析了功能性需求和非功能性需求；其次，根据需求分析设计了系统架构，并进行了详细设计、数据库表设计。这些工作为最终的系统实现与测试打下了坚实的基础。

第6章 面向抑郁症辅助诊断系统的实现与测试

本章实现了面向抑郁症的辅助诊断系统，系统包括患者基本信息的管理、ECG数据的采集和分析、以及抑郁症辅助诊断等功能。可为医生诊断过程提供辅助支持，并为患者提供便利的自查服务。本章将介绍系统的实现及相关测试。

6.1 系统实现

本节在前述需求分析和系统设计基础上，采用面向对象、Web编程等技术实现抑郁症辅助诊断系统。此外，对系统进行了功能性和非功能性测试。

6.1.1 系统开发环境及数据采集

硬件环境：使用具有高性能处理器和足够内存的服务器，以确保系统可以处理大量数据和用户请求。需要一个可靠的网络基础设施，采用高速、稳定的网络设备，确保系统的响应速度和可用性。网络安全也是至关重要的，因此需要配置防火墙、入侵检测系统和其他安全设备，以保护系统免受恶意攻击和数据泄露的威胁。

软件环境：选择windows的操作系统作为系统的基础环境，针对前端开发，选择HTML、CSS、JavaScript等技术，结合流行的前端框架React进行开发；针对后端开发，选择Java与Python语言结合的方式，结合相应的框架Spring Boot进行开发，为了实现隐私数据保护，系统使用加密算法对用户数据进行加密存储，此外，采用SSL/TLS协议确保数据在传输过程中的安全性，并结合安全认证机制确保用户身份的合法性。最后，使用监控工具Grafana进行系统性能监控，并使用日志系统进行日志记录和分析。确保系统能够稳定、安全、高效地运行，并且能够满足用户的需求和期望。

ECG采集环境如图 6-1 所示，患者进行数据的采集时是进行 3 导联的采集，心电图 3 导联是指包括 3 个电极，分别放置在左臂与右臂的连接记录水平方向上的差异，左腿与右臂的连接记录斜向下方向的差异，左腿与左臂的连接记录垂直方向上的差异。通过此 3 导联，医生可以在不同方向上观察心电图的活动，提高心电图的敏感性，有助于对ECG数据进行特征分析以及抑郁症的辅助诊断。

ECG数据集包含了患者在诊断前采集的ECG数据，这些数据涵盖了健康人群和抑郁症患者两大类。




图 6-1 心电图 3 导联

Fig. 6-1 Electrocardiogram 3 Lead

6.1.2 关键算法核心流程

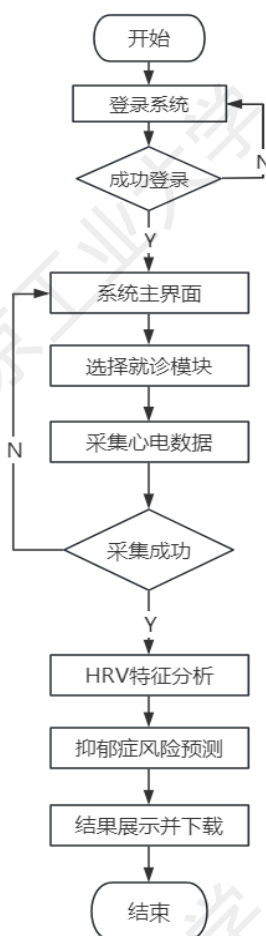


图 6-2 核心模块流程图

Fig. 6-2 Core module flowchart

抑郁症的辅助诊断是本系统的关键任务，系统采用了第4章提出的辅助诊断架构，以多模态特征为输入，尽可能挖掘HRV时频域之间的联系，从而提高模型的准确率。

系统的核心模块流程如图6-2所示。用户首先需要登录系统进入主界面，经过登录校验成功后，可以选择进行ECG数据的采集。若采集过程中出现操作不规范导致信息采集失败，则需要重新进行采集。接着，对采集好的ECG数据进行特征分析和风险预测，得出抑郁症的预测结果，并展示结果并支持用户下载。

6.1.3 系统主要模块实现

为了方便医生和用户管理，设计实现了抑郁症辅助诊断系统并添加了登录验证，以防止系统受到外部攻击而泄露隐私，如图6-3所示。



图 6-3 系统登录图

Fig. 6-3 System Entry Diagram

图6-4所示为系统登录流程图。辅助诊断系统的登录界面要求用户通过用户名和密码验证才能访问系统资源。若没有账号则需要先进行账号的注册才可以登录系统。每天只允许3次登录失败，超过次数会导致账户被锁定，需要联系管理员解锁。

系统登录成功后进入主界面，主界面展示了所有已进行过诊断的患者的详细信息，医生可以对患者姓名进行精确查询以方便查找，医生也可以对出院的患者进行批量删除。图6-5展示了这些功能，旨在方便用户对自身诊断信息和医生对患者、出院信息、住院信息等信息的管理。

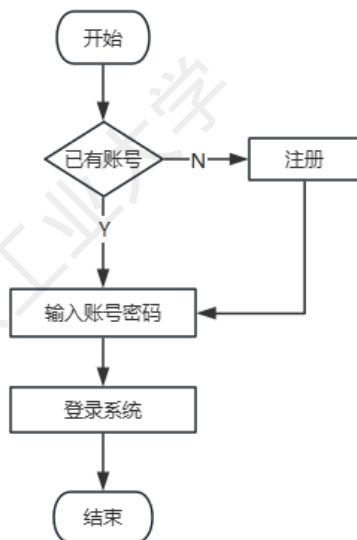


图 6-4 系统登录流程图

Fig. 6-4 System Login Flowchart

用户编号	姓名	性别	邮箱	电话	地址	操作
1	admin	男	104@qq...	1	1	编辑 删除
2	xiaozhao	女	103306...	123	山西临汾	编辑 删除
4	xiaochen	男	104@qq...	13585654585	北京顺义	编辑 删除
5	hxxw	男	10306@...	123456789	朝阳	编辑 删除

图 6-5 用户列表图

Fig. 6-5 User List Graph

如图 6-6 所示，患者心电数据的导入是抑郁症辅助诊断系统的必要基础。在这一步骤中，医生需要确定患者的身份信息，包括是否为住院患者或当天就诊的临时患者，并确定患者所属的组织。随后，医生将患者采集的心电文件导入系统，作为系统的输入。系统将调用诊断模型进行分析，生成患者病情的可视化分析，并输出风险预测的诊断结果。这一过程为医生提供了重要的辅助信息，有助于更准确地诊断抑郁症及评估患者的风险水平，其伪代码如图 6-7 所示。



图 6-6 用户数据导入

Fig. 6-6 User Data Import

```
登录注册模块伪代码
Function login(request):
    If verify(request.username,request.password) then
        Return success
    Else return error(message="用户名或者密码错误")
Function register
    If not valid(request.tel,request.email) then
        Return error(message="填写信息格式错误")
    If valid(request.username) then
        addUser(request.userInfo)
    else
        return error(message="用户名已存在")
End Function
```

图 6-7 用户登录注册模块伪代码

Fig. 6-7 pseudo code for user login and registration module

系统整合了第三章中的数据处理过程和第四章构建的抑郁症辅助诊断模型。在图 6-8 中展示了系统对患者心电文件进行预处理和分析后所生成的病情结果。这些结果不仅包括病情判断，还设定了正常值作为参考，并为医生提供建议。此外，系统将这些数据呈现为可视化结果，以便患者和医生更便于查阅和理解。这

一设计使得诊断过程更加直观和有效，为医疗工作者提供了重要的辅助信息，有助于准确评估患者的抑郁症状并制定相应的治疗方案。其伪代码如图 6-9 所示。



图 6-8 患者病情结果展示图

Fig. 6-8 Patient Outcome Chart

为了便于患者查看诊断结果信息，系统支持患者下载诊断结果。如图 6-10 所示，在PDF文件中，展示了患者诊断后生成的心率变异性特征分析以及心理和身体放松指数。通过这些指数，患者可以了解自己可能患有抑郁症，尤其是当指数偏低时，表明患者面临较大压力。此外，文件还附带了诊断系统的预测结果，为患者提供全面的诊断信息。这种功能设计有助于患者更好地了解自己的病情，促进患者与医生之间的沟通，同时提高了患者对治疗方案的参与度。

辅助诊断模块伪代码

```
Function file(request):  
If exist(request file) then,  
    data = dataProcessing(file),  
    hrv = hrvAnalysis(data),  
    result = modelResult(hrv),  
    return result  
Else return error(message="文件上传失败")  
Function dataProcessing(file),  
Function hrvAnalysis(data),  
    hrvFeatures = extractFeatures(data),  
return hrvFeatures,  
Function modelResult(hrv),  
    predictionRes = predic(hrv),  
return predictionRes,  
End Function,
```

图 6-9 辅助诊断模块伪代码

Fig. 6-9 Pseudocode for the auxiliary diagnostic module



图 6-10 结果数据导出图

Fig. 6-10 Resulting Data Export Diagram

6.2 系统测试

本节将基于系统的功能实现进行系统测试，主要包含系统测试的环境介绍、系统的基本功能测试和系统的性能测试。

6.2.1 系统测试环境

(1) 硬件配置：建立一个与生产环境相似的测试服务器，包括高性能处理器、足够的内存和存储容量。这样可以确保在测试过程中能够模拟真实的用户负载和数据量。需要一个独立的网络基础设施，以防止测试对生产环境造成干扰

(2) 软件配置：测试环境的操作系统应该与生产环境相同，以确保测试结果的可靠性和一致性。选择MOCK工具来进行功能测试、性能测试和安全测试，测试环境也需要配置监控工具和日志系统，用于实时监控运行状态和记录测试过程中的日志信息。这样可以及时发现和解决测试过程中出现的问题，确保测试的顺利进行。建立一个完善的测试环境对于心理康复管理系统的开发和部署至关重要。通过在测试环境中进行全面的测试、性能测试和安全测试，可以最大程度地确保系统的稳定性和可靠性，提高用户体验和满意度

6.2.2 系统功能测试

系统功能测试旨在验证系统的各项功能是否按照需求规格书或设计文档中所描述的要求正常运行，可以帮助确认系统是否符合用户需求和预期。通过按照需求规格书中的功能列表逐项测试，可以验证系统是否实现了用户所期望的功能，并且功能是否按照规定的方式运行。可以帮助发现系统中存在的功能缺陷和错误，通过模拟用户的操作流程，可以发现系统中可能存在的逻辑错误、界面异常或功能不完善的情况，从而及时进行修复和优化。可以确保系统在各种使用情况下的稳定性和可靠性。通过测试系统在各种边界条件下的功能表现，可以发现系统可能存在的稳定性问题和异常情况，从而确保系统能够在不同情况下稳定运行，测试用例见表 6-1。

本次测试主要涉及用户注册功能、系统登录功能、患者心电数据导入功能、患者HRV分析功能、辅助诊断功能、结果导出以及组织管理等功能。其中，用户注册时需要先点击注册按钮，根据页面中的提示信息进行信息的完善，通过格式校验后显示注册成功。注册好以后进行系统登录，输入注册时产生的账号和密码，通过账号和密码校验后成功登录系统。根据患者登录日期选择所属组织方便进行

管理。进行诊断时首先需要进行心电数据文件的上传，上传成功后系统根据心电数据文件解析并分析其HRV特征，给出分析结果；同时使用嵌入的模型给出患者的辅助诊断结果。为了方便患者诊断结果的可阅读性，系统提供了下载功能，患者可将诊断结果进行下载保存为PDF格式，可以在不需要登录系统的情况下进行诊断结果的查看。

表 6-1 功能测试用例表

Tab. 6-1 Functional Test Case Form

测试内容	测试步骤	预期结果	测试结果
用户的注册	1.打开登陆界面，点击下方注册按钮。 2.根据提示输入表格中信息。 3.点击注册。	显示用户注册成功。	测试通过
登录系统	1.打开登录页面。 2.输入用户名和密码。 3.点击登录。	登录成功，用户可以根据自己角色做相应的操作。	测试通过
导入患者数据，得出初步诊断	1.登录系统。 2.进入网站主页面。 3.患者采集心电数据。 4.导入患者心电文件。 5.选择“诊断”功能。	系统根据患者的心电数据，给出HRV的特征分析结果	测试通过
结果导出	1.登录系统 2.进入网站主页面 3.点击“结果导出”按钮	系统根据患者id，导出此患者对应的所选择日期的诊断结果，导出为PDF文件。	测试通过
二级组织的管理	1.登录系统。 2.点击所属医院。 3.点击一级组织。 4.点击查询、新增、修改按钮。	系统在一级组织下，成功创建二级组织，为树形结构。	测试通过

6.2.3 系统性能测试

系统性能评估测试的目的是评估系统在不同负载和压力下的运行性能和稳定性，可以帮助确定系统在正常负载情况下的响应时间和吞吐量。通过模拟多个用户同时访问系统，可以评估系统的并发处理能力，从而确定系统是否能够满足用户的需求并保持良好的性能表现。可以帮助发现系统中存在的性能瓶颈和性能不佳的部分。通过监测系统在不同负载下的性能指标，可以识别出造成性能问题的原因，进而采取相应的优化措施，提高系统的性能和稳定性。可以验证系统在不同规模和负载下的可伸缩性和扩展性。通过逐步增加负载，可以评估系统在不同规模下的性能表现，并确定系统是否能够在需要时进行扩展以应对更大的负载。

可以帮助确保系统在长时间运行和高负载情况下的稳定性和可靠性。通过模拟真实场景下的使用情况，可以发现系统在长时间运行过程中可能出现的问题，从而及时进行修复和优化，确保系统能够持续稳定地运行，提供良好的用户体验，测试用例见表 6-2。

表 6-2 性能测试用例表

Tab. 6-2 Performance Test Case Table

测试内容	测试步骤	预期结果	测试结果
系统对操作的响应时间	1.进入系统主界面。 2.多次点击网站主界面	系统页面渲染时间平均在 1s 之内。	测试通过
系统流量压测	1.使用压测工具模拟多个请求 2.发起诊断请求	系统可以正常运行，访问不超时。	测试通过
系统磁盘利用率	1.模拟开启多个用户，同时登录访问系统 2.使用统计工具查看磁盘利用率随时间的变化	磁盘利用率最高为 80%	测试通过
系统CPU利用率	1.模拟多用户登录，同时访问系统 2.使用统计工具查看cpu利用率随时间的变化	CPU利用率最高为 80%	测试通过
系统吞吐量	在系统运行时，使用监视工具统计一个小时有多少用户访问系统	得出单位时间内的请求数量	测试通过
负载均衡	1.部署两台机器 2.使用监视工具统计打在每台服务器的流量	高峰期或正常情况下可正常运行	测试通过
稳定性、可靠性	1.部署服务并长时间运行	一段时间后用户访问正常	测试通过

在测试系统性能方面，我们进行了一系列测试以确保系统的稳定性和可靠性。首先，对系统的响应时间进行测试，我们进入系统主界面并多次点击网站主界面，预期系统页面渲染时间平均在 1 秒之内，并测试结果显示符合预期。另外，针对系统流量进行压力测试，使用压测工具模拟多个请求并发起诊断请求，确保系统可以正常运行且访问不会超时，测试顺利通过。

对系统的磁盘利用率和CPU利用率进行了测试，通过模拟开启多个用户同时登录访问系统以及多用户访问下的CPU利用率监控，结果显示磁盘利用率和CPU利用率最高均为 80%，测试结果积极通过。此外，对系统的吞吐量进行了监测，统计一个小时有多少用户访问系统，并得出单位时间内的请求数量，测试结果符合预期。

最后，课题组部署了两台机器进行系统的负载均衡和可靠性测试。测试中，使用监视工具统计每台服务器的流量，确保系统在高峰期或正常情况下都能正常

运行。对系统进行长时间运行测试后,用户访问依然正常访问并使用系统,系统的稳定性和可靠性经受住了考验。

此外,非功能测试是为了评估系统在非功能性方面的表现,包括性能、安全性、可用性、可靠性等。测试用例表见表 6-3。

表 6-3 非功能性测试用例表

Tab. 6-3 Non-functional Test Case List

测试内容	测试步骤	预期结果	测试结果
脚本攻击	在表单中提交sql攻击的语句	非法请求被拦截	测试通过
密码是否加密	查看数据库中的密码	密码已经加密为 64 位	测试通过
日志打印	访问接口功能	日志正常打印	测试通过
请求头校验	访问接口时携带过期的请求头	校验请求头,发现错误并返回错误码	测试通过

针对系统安全性进行了一系列测试,以确保系统能够有效地应对潜在的安全威胁。首先,进行了脚本攻击测试,通过在表单中提交SQL注入攻击语句,期望系统能够拦截非法请求,测试结果显示非法请求被成功拦截,测试通过。

其次,在密码安全性方面进行了测试,查看数据库中的密码存储方式,预期密码已经被加密为 64 位形式,测试结果表明密码已经加密存储,符合预期,测试通过。同时,对日志打印功能进行了测试,通过访问接口功能,期望系统正常打印相关日志信息,测试结果显示日志正常打印,测试通过。

最后,进行了请求头校验测试,通过访问接口时携带过期的请求头,预期系统能够校验请求头,发现错误并返回错误码,测试结果显示系统成功校验请求头并返回相应错误码,测试通过。

综合以上测试结果,系统在安全性方面表现稳定,能够有效地应对潜在的安全威胁,系统安全性得到有效保障。

6.3 本章小结

本章介绍了面向抑郁症辅助诊断系统的实现和相关测试。在系统实现方面,详细介绍了抑郁症辅助诊断模型开发环境、关键算法以及主要功能模块的实现。其次,通过对关键算法实现和模块实现的功能测试和性能测试,验证了系统的有效性。

总结与展望

随着社会发展人们的工作生活节奏日益加快,个体承受的心理压力也越来越大,心理健康日益成为社会关注的热点。据报道,我国精神疾病患者数量已超过 1.73 亿,其中抑郁症患者超过 7000 万,且复发率高达 75%。每年自杀或自杀未遂的人群中,有一半以上患有抑郁症。面对如此众多心理健康需求人群,中国目前专业心理医生仅有约 2000 多名,迫切需要研发简便、高效的心理健康检测辅助技术和工具。

针对高效准确抑郁症辅助检测问题,本文将心电信号的心率变异性作为研究主体,对原始心电数据进行了预处理,通过识别心电信号的波峰来获取RR时间间隔序列,基于RR间隔序列分析并提取了心率变异性的时频域特征,将心率变异性时频域特征共同作为模型的输入构建了基于深度学习的分类模型,设计实现了抑郁症辅助诊断系统。主要研究内容和成果如下:

(1) 对原始心电数据进行滤波、降噪和基线漂移的去除,采用自适应阈值法对心电信号的R峰进行定位,并提取出RR间隔序列;利用滑动窗口对一维时间间隔序列进行切片,在切片基础上进行HRV的时频域特征分析;提出一种基于心率变异性的抑郁症辅助诊断网络。该网络以患者ECG数据特征作为模型的输入;并利用残差网络进行特征向量的提取及分类,实验结果表明,该模型的抑郁症辅助诊断准确率达到 80%,为后续多模态技术研究提供了基础。

(2) 提出一种基于多模态特征融合的抑郁症辅助诊断网络,该网络架构融合了ResNet18、注意力机制和多层感知机技术。首先,通过ResNet18 提取频域特征向量;其次,引入注意力机制来衡量时频域特征的权重,将含有注意力权重的时频域特征向量进行融合,以达到充分提取特征的效果;最后,通过多层感知机进行二分类辅助诊断抑郁症。实验表明该方法优于单模态数据的预测算法。

(3) 设计并实现一个面向抑郁症的辅助诊断系统。本文采用面向对象技术对面向抑郁症的辅助诊断系统进行了分析设计,并编程实现了系统。此外,对系统进行了功能测试和性能测试,并结合公开数据集SHAREE对系统进行实验和结果分析。实验结果表明,该系统的诊断准确率达到 87%,证实了系统在辅助抑郁症诊断方面的高效性和可信度。此外,实验证明了系统具有较高的可靠性和实时性,能够有效地满足抑郁症辅助诊断的实际需求,为患者提供更好的医疗支持和服务。

鉴于时间和精力的限制,本课题尚存在一些不足之处,需要在未来的研究中进行进一步完善和深入探讨:

(1) 抑郁症具有复杂的发病机理，本文只关注心电信号是否与抑郁症风险相关，并存在研究局限。需引入更多生理信号和生化指标，比如呼吸、脉搏、血氧等，建立多角度、多元素的研究以全方位探究抑郁症的生理机制。

(2) 医疗数据的隐私性和特殊性使得公开的数据集相对稀缺且规模较小，这给医疗领域的研究和应用带来了一定的挑战。因此，未来的研究可以聚焦于医疗数据集的整合和构建，以解决当前数据稀缺和规模较小的问题。同时，还可以探索基于人工智能和大数据分析的方法，从非传统的数据源中获取医疗信息，进一步丰富和扩展医疗数据集的内容和规模。

参考文献

- [1] 周敏. 大学生心理韧性、核心自我评价与抑郁、焦虑情绪的关系研究[D]. 长沙:中南大学, 2014.
- [2] Organization W H. “Depression: let’s talk” says WHO, as depression tops lists of causes of ill health[M]. Website of WHO, 2017.
- [3] Shah J A ,Veledar E ,Hong Y , et al. Depression and History of Attempted Suicide as Risk Factors for Heart Disease Mortality in Young Individuals[J]. Archives of General Psychiatry,2011,68(11):1135-1142.
- [4] P P C ,C J W ,J M L , et al. Caregiving and all-cause mortality in postmenopausal women: findings from the Women's Health Initiative[J]. Journal of the American Geriatrics Society,2023,72(1):24-36.
- [5] Kexin Z ,Min W ,Li Y , et al. Latent profile analysis of the symptoms of depression and activities of daily living impairment among older adults[J]. Rehabilitation psychology,2023,69(1):45-54.
- [6] 万钰縛,欧红霞.抑郁症患者家庭照料者负担研究进展[J]. 神经疾病与精神卫生,2019, 19(6): 626-630.
- [7] You J, Li H, Xie D, et al. Acupuncture for Chronic Pain-Related Depression: A Systematic Review and Meta-Analysis[J]. Pain Research & Management, 2021, 2021: 6617075-6617075.
- [8] 李献云,费立鹏,张艳萍等.抑郁症诊断筛查量表的编制及其效度检验[J].中国神经精神疾病杂志,2007,(05):257-263.
- [9] Colombo J, Arora R, DePace N L, et al. Clinical Autonomic Dysfunction[J]. Switzerland: Springer International Publishing, 2015: 27-52.
- [10] Arora R, Krummerman A, Vijayaraman P, et al. Heart rate variability and diastolic heart failure[J]. Pacing and Clinical Electrophysiology, 2004, 27(3): 299-303.
- [11] Ksela J, Rupert L, Djordjevic A, et al. Altered Heart Rate Turbulence and Variability Parameters Predict 1-Year Mortality in Heart Failure with Preserved Ejection Fraction[J]. Journal of Cardiovascular Development and Disease, 2022, 9(7): 213-213.
- [12] Shanks J, Abukar Y, Lever N A, et al. Reverse re-modelling chronic heart failure by reinstating heart rate variability[J]. Basic Research in Cardiology, 2022, 117(1): 4-4.
- [13] Yue W W, Yin J, Chen B, et al. Analysis of heart rate variability in masked hypertension[J]. Cell Biochemistry and Biophysics, 2014, 70(1): 201-204.
- [14] Virtanen R, Jula A, Kuusela T, et al. Reduced heart rate variability in hypertension: associations with lifestyle factors and plasma renin activity[J]. Journal of Human Hypertension, 2003, 17(3): 171-179.
- [15] Kang J, Chang Y, Kim Y, et al. Ten-second heart rate variability, its changes over time, and the development of hypertension[J]. Hypertension, 2022, 79(6): 1308-1318.
- [16] Sharma M, Rajput J S, Tan R S, et al. Automated detection of hypertension using physiological

- signals: a review[J]. *International Journal of Environmental Research and Public Health*, 2021, 18(11): 5838.
- [17] Udawat A S, Singh P. An automated detection of atrial fibrillation from single-lead ECG using HRV features and machine learning[J]. *Journal of Electrocardiology*, 2022, 75: 70-81.
- [18] Buś S, Jędrzejewski K, Guzik P. Using Minimum Redundancy Maximum Relevance Algorithm to Select Minimal Sets of Heart Rate Variability Parameters for Atrial Fibrillation Detection[J]. *Journal of Clinical Medicine*, 2022, 11(14): 4004-4004.
- [19] Shirakawa Y, Niwano S, Oikawa J, et al. Prediction of lethal arrhythmic events through remote monitoring using heart rate variability analysis in patients with an implantable cardioverter defibrillator[J]. *International Heart Journal*, 2020, 61(5): 927-935.
- [20] Ebrahimzadeh E, Pooyan M, Bijar A. A Novel Approach to Predict Sudden Cardiac Death (SCD) Using Nonlinear and Time-Frequency Analyses from HRV Signals[J]. *PLOS ONE*, 2014, 9(2): 1-14.
- [21] Martinez-Alanis M, Bojorges-Valdez E, Wessel N, et al. Prediction of sudden cardiac death risk with a support vector machine based on heart rate variability and heartprint indices[J]. *Sensors*, 2020, 20(19): 5483.
- [22] 王莹,李云峰,程祺等.儿童焦虑症的心率变异性频谱分析[J].*中国健康心理学杂志*,2017,25(01):13-15.
- [23] 覃晓波,陶建青,张琴等.广泛性焦虑患者焦虑程度与心率变异性相关研究[J].*中国全科医学*,2012,15(10):1117-1119.
- [24] Kemp A H, Quintana D S, Gray M A, et al. Impact of depression and antidepressant treatment on heart rate variability: a review and meta-analysis [J]. *Biological Psychiatry*, 2010, 67(11): 1067-1074.
- [25] Udupa K, Sathyaprabha T N, Thirthalli J, et al. Alteration of cardiac autonomic functions in patients with major depression: A study using heart rate variability measures[J]. *Journal of Affective Disorders*, 2007, 100(1-3): 137-141.
- [26] 冯永生,冯胜红.抑郁患者的心率变异性分析[J].*华西医学*,2007, 22(4):806-807.
- [27] Van der Kooy K G, Van Hout H P, et al. Differences in heart rate variability between depressed and non-depressed elderly[J]. *International Journal of Geriatric Psychiatry*, 2006, 21(2): 147-150.
- [28] Shinba T. Altered autonomic activity and reactivity in depression revealed by heart-rate variability measurement during rest and task conditions[J]. *Psychiatry & Clinical Neurosciences*, 2014, 68(3): 225-233.
- [29] Gruber J, Mennin D S, Fields A, et al. Heart rate variability as a potential indicator of positive valence system disturbance: a proof of concept investigation[J]. *International Journal of Psychophysiology*, 2015, 98(2): 240-248.
- [30] Yeh T C, Kao L C, Tzeng N S, et al. Heart rate variability in major depressive disorder and after antidepressant treatment with agomelatine and paroxetine: Findings from the Taiwan

- Study of Depression and Anxiety (TAISDA)[J]. Progress in Neuro-Psychopharmacology and Biological Psychiatry, 2016, 64: 60-67.
- [31] Chen X, Yang R, Kuang D, et al. Heart rate variability in patients with major depression disorder during a clinical autonomic test[J]. Psychiatry Research, 2017, 256: 207-211.
- [32] Valenza G, Gentili C, Lanatí A, et al. Mood recognition in bipolar patients through the PSYCHE platform: Preliminary evaluations and perspectives[J]. Artificial Intelligence in Medicine, 2013, 57(1): 49-58.
- [33] Tolentino J C, Schmidt S L. Association between depression severity and cardiac autonomic modulation[J]. Journal of Psychosomatic Research, 2016, 85: 9-11.
- [34] Yayun W ,Shengda L .Valuing equity-linked guaranteed minimum death benefits with European-style Asian payoffs under a regime switching jump-diffusion model[J]. Communications in Nonlinear Science and Numerical Simulation,2024,128
- [35] Saghafi A, Jazayeri S, Esmaili S, et al. Real-time object detection using power spectral density of ground-penetrating radar data[J]. Structural Control and Health Monitoring, 2019, 26(6): e2354.
- [36] Jakubowski J, Jackowski J. Recognition of moving tracked and wheeled vehicles based on sound analysis and machine learning algorithms[J]. International Journal of Automotive and Mechanical Engineering, 2021, 18(1): 8478–8488.
- [37] Gościewska K, Frejlichowski D. Recognizing human actions with multiple Fourier transforms[J]. Procedia Computer Science, 2020, 176: 1083-1090.
- [38] Vinnett L, Sovechles J, Gomez C O, et al. An image analysis approach to determine average bubble sizes using one-dimensional Fourier analysis[J]. Minerals Engineering, 2018, 126: 160-166.
- [39] Simon M ,Barbara S K .Deep Neural Networks for Image-Based Dietary Assessment[J]. Journal of visualized experiments : JoVE,2021,(169):
- [40] Shamsolmoali P ,Zareapoor M ,Wang R , et al. A Novel Deep Structure U-Net for Sea-Land Segmentation in Remote Sensing Images[J]. IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing,2019,12(9):3219-3232.
- [41] Ibrahim O A ,Abd A A R .Hepatic vessels segmentation using deep learning and preprocessing enhancement[J]. Journal of applied clinical medical physics,2023,24(5):e13966-e13966.
- [42] Donghyeon L ,Eunho L ,Youngbae H .Lossless Reconstruction of Convolutional Neural Network for Channel-Based Network Pruning[J]. Sensors,2023,23(4):2102-2102.
- [43] Ajmal S ,Hyun K J .Deep Atrous Spatial Features-Based Supervised Foreground Detection Algorithm for Industrial Surveillance Systems[J]. IEEE TRANSACTIONS ON INDUSTRIAL INFORMATICS,2021,17(7):4818-4826.
- [44] Fraser J, Aricibasi H, Tulpan D, et al. A computer vision image differential approach for automatic detection of aggressive behaviour in pigs using deep learning[J]. Journal of Animal Science, 2023, 101: 347-347.

- [45] Kumar P, Suresh S. Deep learning models for recognizing the simple human activities using smartphone accelerometer sensor[J]. IETE Journal of Research, 2023, 69(8): 5148-5158.
- [46] M S A ,F N S ,Salah E , et al.Bacterial classification with convolutional neural networks based on different data reduction layers[J]. Nucleosides, nucleotides nucleic acids,2020,39(4):493-03.
- [47] Anne-Marie R ,Guha A R ,Ignacio S , et al. Recalibrating 3D ConvNets with Project Excite[J]. IEEE transactions on medical imaging,2020,PP(99):1-1.
- [48] Kumar M S ,Hussain R L ,Joyeeta S , et al. Hybrid deep learning model-based human action recognition in indoor environment[J]. Robotica,2023,41(12):3788-3817.
- [49] Reddy M R Y , Muralidhar P . A high-speed reusable quantized hardware accelerator design for CNN on constrained edge device[J]. Design Automation for Embedded systems,2023,27(3):165-189.
- [50] Babitha P ,Zhenyu X ,Hamad A , et al. ASENN: attention-based selective embedding neural networks for road distress prediction[J]. Journal of Big Data,2023,10(1):
- [51] Alexios L I ,Spyridon N ,Panagiotis S , et al. Artwork Style Recognition Using Vision Transformers and MLP Mixer[J]. Technologies,2021,10(1):2-2.
- [52] Pendar A ,Michael S ,Frieder S .Improving Deep Learning-based Plant Disease Classification with Attention Mechanism[J]. Gesunde Pflanzen,2022,75(1):49-59.
- [53] Lu J ,Chen L ,Meng K , et al. Identifying User Profile by Incorporating Self-Attention Mechanism based on CSDN Data Set[J]. Data Intelligence,2019,1(2):160-175..
- [54] Zohourianshahzadi ,Zanyar,Kalita , et al. Neural attention for image captioning: review of outstanding methods[J]. Artificial Intelligence Review,2021,55(5):1-30.
- [55] Kai S G ,Wen S W ,Hui L , et al. Multi-Feature Fusion Based Structural Deep Neural Network for Predicting Answer Time on Stack Overflow[J]. Journal of Computer Science and Technology,2023,38(3):582-599.
- [56] Naaima S ,Arunima J ,Nitin S .Stack Ensemble Oriented Parkinson Disease Prediction Using Machine Learning Approaches Utilizing GridSearchCV-Based Hyper Parameter Tuning[J]. Critical reviews in biomedical engineering,2022,50(5):39-58.
- [57] Zoucas M A F ,Belfiore P.An empirical analysis of a neural network model for the time series forecasting of different industrial segments[J]. Int. J. of Applied Decision Sciences,2015,8(3):261-283.
- [58] Xia ,Kai-Jian,Yin , et al. X-ray Image Enhancement Base on the Improved Adaptive Low-Pass Filtering[J]. Journal of Medical Imaging and Health Informatics,2018,8(7):1342-1348(7).
- [59] Enes F O ,Ahmet A ,Thorsten S .Emotion detection from ECG signals with different learning algorithms and automated feature engineering[J]. Signal, Image and Video Processing,2023,17(7):3783-3791.
- [60] Fallahi M ,Motamedzade M ,Heidarimoghadam R , et al. Effects of mental workload on physiological and subjective responses during traffic density monitoring: A field study[J].

- Applied Ergonomics,2016,5295-103..
- [61] Sadr N ,Jayawardhana M ,Pham T T , et al.A low-complexity algorithm for detection of atrial fibrillation using an ECG[J]. Physiological Measurement,2018,39(6):064003-064003.
- [62] Prystavka P ,Dukhnovska K ,Kovtun O , et al. Devising information technology for determining the redundant information content of a digital image[J]. Eastern-European Journal of Enterprise Technologies,2021,6(2):59-70.
- [63] Sakib M K ,Nishat S ,Rabiul G M A , et al. CNN-XGBoost fusion-based affective state recognition using EEG spectrogram image analysis[J]. Scientific Reports,2022,12(1):14122-14122.
- [64] Vijaya P ,Monalisa M ,Kumar A S .Identification of COVID-19 using chest X-Ray images[J]. Computer Methods in Biomechanics and Biomedical Engineering: Imaging Visualization,2023,11(6):2130-2144.
- [65] Serhat K .A novel nonlinear hybrid HardSReLU activation function in transfer learning architectures for hemorrhage classification[J]. multimedia Tools and Applications,2022,82(4):6345-6365.
- [66] Partridge T, Astolfo A, Buchanan I, et al. Reliable extraction of x-ray refraction and dark-field signals with a large field of view, multi-modal scanning system at spectral energies up to 150 kVp[J]. Journal of Physics D: Applied Physics, 2024, 57(17): 175104.
- [67] Mohammed A ,Faisal S ,H. E A , et al. An Aggregated Mutual Information Based Feature Selection with Machine Learning Methods for Enhancing IoT Botnet Attack Detection[J]. Sensors,2021,22(1):185-185.
- [68] N. R ,G. N .Persian text classification using naive bayes algorithms and support vector machine algorithm[J]. Indonesian Journal of Electrical Engineering and Informatics,2020,8(1):178-188.
- [69] Singh K A ,Kumar S ,Bhushan S , et al. A Proportional Sentiment Analysis of MOOCs Course Reviews Using Supervised Learning Algorithms[J]. ISI,2021,26(5):501-506.

攻读硕士学位期间取得的研究成果

[1] Yong Zhao,Jian He. Assisted Prediction of Hypertension Based on Heart Rate Variability and Improved Residual Networks. International Journal of Computer and Information Engineering 2024.（期刊论文，已发表）

[2] 赵勇，心理康复管理系统，国家计算机软件著作权，授权登记号：2023SR0517716（已授权）

致谢

行文至此，思绪万千，三年硕士生涯即将落下帷幕。

首先感谢我的导师何老师，严谨认真的工作态度，体现在对我的论文要求中，从开题、到实验指导，指导我确定研究方向，如何开展研究，在到最后的论文撰写，一遍又一遍的帮助我修改论文。

其次感谢我的父母，作为家里的第一代研究生，是他们给了我力量与底气才能在求学道路上坚持下去。

最后感谢我的同门、师兄师姐、师弟师妹，他们在我科研路上给予帮助，生活路上给予欢乐，愿他们一切顺利。

